Tasca 2: MODELS PARAMÈTRICS DE SUPERVIVÈNCIA

Mario Aragón, Laura Belmonte, Lena Lledós, Miguel Rodríguez

2026-03-04

Índex

Introducció **3**

Models Paramètrics **4**
Models . . . 10
Exponencial . . . 10
Weibull . . . 10
Exponencial vs Weibull . . . 11
Log-logistic . . . 11
Hipòtesis dels models i criteris de validació . . . 12
Evidència del compliment de les hipòtesis . . . 15
Criteris de validació dels models . . . 15

Interpretació model **16**
Paràmetre escala . . . 16
Factor d'acceleració (AFT) . . . 16
Hazard Ratio (PH) per Weibull . . . 17
Relacions & Coherències . . . 18

Anàlisi amb variables **19**
Variable Age . . . 19
Variable IBM . . . 22
Conjuntament . . . 26
Model escollit . . . 31
Factors d'acceleració del millor model . . . 33
HR . . . 35

Conclusion **35**

Introducció

En aquesta tasca es practicaran els models paramètrics de regressió més utilitzats en l'anàlisi de la supervivència, concretament els models exponencial, Weibull i log-logístic. Les dades a utilitzar són "whas100.txt". En aquestes dades s'ha mesurat el temps, en dies, fins la mort dels pacients que han ingressat a l'hospital amb un infart agut de miocardi. L'objectiu principal és estudiar si hi ha diferències en els temps de supervivència dels pacients segons el gènere, ajustant per l'edat i l'índex de massa corporal. Per fer-ho, s'ajustaran diferents models paramètrics sota les hipòtesis de temps de vida accelerat (AFT), riscos proporcionals (PH) i odds proporcionals (PO), comparant els models mitjançant criteris com l'AIC i el test de raó de versemblança. Els resultats s'interpretaran en termes de factors d'acceleració (FA) i hazard ratios (HR), i es contrastarà si homes i dones presenten la mateixa supervivència davant d'un episodi d'infart agut de miocardi.

Es carreguen les llibreries necessàries i les dades.

```r
library(knitr)
library(survival)
library(survminer)
```

Les variables a estudiar en aquest estudi són:

Variables	Descripció
lenfol	Temps en dies fins la mort del pacient
fstat	Indicador de censura per la dreta (censurat/observat)
gender	Gènere del pacient (0=Home, 1=Dona)
fage	Edat (menors de 70 anys (<70), majors de 70 anys (70+))
fbmi	Índex massa corporal (kg/m^2) (Baix (menys de 25), Alt (25+))

```
##      lenfol         fstat           age            gender          bmi
##  Min.   :   6   Min.   :0.00   Min.   :32.00   Min.   :0.00   Min.   :14.92
##  1st Qu.: 715   1st Qu.:0.00   1st Qu.:59.75   1st Qu.:0.00   1st Qu.:23.54
##  Median :1878   Median :1.00   Median :71.00   Median :0.00   Median :27.19
##  Mean   :1505   Mean   :0.51   Mean   :68.25   Mean   :0.35   Mean   :27.04
##  3rd Qu.:2076   3rd Qu.:1.00   3rd Qu.:80.25   3rd Qu.:1.00   3rd Qu.:30.35
##  Max.   :2719   Max.   :1.00   Max.   :92.00   Max.   :1.00   Max.   :39.94
##       fage           fbmi
##  Min.   :0.00   Min.   :0.00
##  1st Qu.:0.00   1st Qu.:0.00
##  Median :1.00   Median :1.00
##  Mean   :0.51   Mean   :0.64
##  3rd Qu.:1.00   3rd Qu.:1.00
##  Max.   :1.00   Max.   :1.00
```

Per tal d'aplicar el nostre estudi a un cas concret, es realitza una anàlisi de dades de supervivència corresponents a pacients ingressats per un infart agut de miocardi. La variable principal d'interès és el temps, mesurat en dies, fins a la mort del pacient (lenfol), tenint en compte la presència de censura per la dreta mitjançant l'indicador fstat. Com a variable explicativa principal s'utilitza el gènere del pacient (gender), ajustant per l'edat categoritzada (fage) i l'índex de massa corporal (fbmi), amb l'objectiu d'avaluar si homes i dones presenten diferències en la supervivència després d'un infart agut de miocardi mitjançant models paramètrics de regressió.

L'objectiu principal és avaluar si existeixen diferències en els temps de supervivència segons el gènere dels pacients (gender). Atès que l'edat (fage) i l'índex de massa corporal (fbmi) poden influir en la supervivència, l'anàlisi es realitzarà ajustant per aquestes variables mitjançant models paramètrics de regressió. En concret, es pretén determinar si homes i dones presenten la mateixa funció de supervivència després d'un episodi d'infart agut de miocardi, tenint en compte possibles efectes de confusió i interacció associats a l'edat i a

l'índex de massa corporal. Per fer-ho, s'ajustaran i compararan els models exponencial, Weibull i log-logístic, i els resultats s'interpretaran en termes de factors d'acceleració (FA) i hazard ratios (HR).

Models Paramètrics

D'entre els diferents models paramètrics estudiats, s'avaluaran aquells que puguin ajustar-se millor a les dades per tal d'identificar quin és el més adequat. Escollir el model més apropiat permetrà realitzar una anàlisi més exhaustiva amb la resta de variables de la base de dades i reduir el risc d'interpretar de manera incorrecta les relacions observades.

Model exponencial

$$h(t) = \lambda = \exp(\beta_0 + \beta_1 \,\mathrm{TRT})$$

$$\mathrm{TRT} = 1: \quad h(t) = \exp(\beta_0 + \beta_1)$$

$$\mathrm{TRT} = 0: \quad h(t) = \exp(\beta_0)$$

$$\mathrm{HR}(\mathrm{TRT} = 1 \text{ vs. } \mathrm{TRT} = 0) = \frac{\exp(\beta_0 + \beta_1)}{\exp(\beta_0)} = \exp(\beta_1)$$

model de weibull

$$S(t) = \exp(-\lambda t^p) \;\Rightarrow\; t = [-\ln(S(t))]^{1/p} \times \frac{1}{\lambda^{1/p}}$$

$$\text{Let } \frac{1}{\lambda^{1/p}} = \exp(\alpha_0 + \alpha_1 \mathrm{TRT}),$$

$$t = [-\ln(S(t))]^{1/p} \times \exp(\alpha_0 + \alpha_1 \mathrm{TRT})$$

$$\text{Let } S(t) = q, \quad t = [-\ln(q)]^{1/p} \times \exp(\alpha_0 + \alpha_1 \mathrm{TRT})$$

$$\text{Acceleration Factor: } \gamma \text{ (TRT} = 1 \text{ vs. TRT} = 0)$$

$$\gamma = \frac{[-\ln(q)]^{1/p} \times \exp(\alpha_0 + \alpha_1)}{[-\ln(q)]^{1/p} \times \exp(\alpha_0)} = \exp(\alpha_1)$$

model de log-logistic

$$S(t) = \frac{1}{1 + \lambda t^p} = \frac{1}{1 + \left(\lambda^{1/p} t\right)^p}$$

$$t = \left[\frac{1}{S(t)} - 1\right]^{1/p} \cdot \frac{1}{\lambda^{1/p}}$$

$$\text{Let } \frac{1}{\lambda^{1/p}} = \exp(\alpha_0 + \alpha_1 \,\text{WBCCAT})$$

$$t = \left[\frac{1}{S(t)} - 1\right]^{1/p} \cdot \exp(\alpha_0 + \alpha_1 \,\text{WBCCAT})$$

$$\text{Let } S(t) = q, \quad t = \left[q^{-1} - 1\right]^{1/p} \cdot \exp(\alpha_0 + \alpha_1 \,\text{WBCCAT})$$

$$\text{Acceleration Factor: } \gamma \text{ (WBCCAT} = 2 \text{ vs. WBCCAT} = 1)$$

$$\gamma = \frac{\left[q^{-1} - 1\right]^{1/p} \exp(\alpha_0 + 2\alpha_1)}{\left[q^{-1} - 1\right]^{1/p} \exp(\alpha_0 + \alpha_1)} = \exp(\alpha_1)$$

$$\begin{aligned} \text{AFT: } \lambda^{1/p} &= \exp[-(\alpha_0 + \alpha_1 \text{TRT})] \\ (1/p) \ln \lambda &= -(\alpha_0 + \alpha_1 \text{TRT}) \\ \ln \lambda &= -p\,(\alpha_0 + \alpha_1 \text{TRT}) \end{aligned}$$

$$\begin{aligned} \text{PO: } \lambda &= \exp(\beta_0 + \beta_1 \text{TRT}) \\ \ln \lambda &= \beta_0 + \beta_1 \text{TRT} \end{aligned}$$

$$\beta_1 = -\alpha_1 \cdot p \;=\; FOR = \left(\frac{1}{\gamma}\right)^p$$

Abans de comenzar a comprabar mitjançant diferentes eines sobre l'ajustament de les dades:

```
surv.whas <- with(data, Surv(lenfol, fstat))
km.gender <- survfit(surv.whas ~ gender, data = data)
km.gender
```

```
## Call: survfit(formula = surv.whas ~ gender, data = data)
##
##            n events median 0.95LCL 0.95UCL
## gender=0 65     28   2624    2012      NA
## gender=1 35     23   1806     841      NA
```

```
ggsurvplot(km.gender, data = data, conf.int = TRUE,
           xlab = "Temps en dies", ylab = "Supervivència",
           legend.labs = c("Home", "Dona"),
           title = "Funcions de Supervivència KM per Gènere",
           palette = c("#2E9FDF", "#E7B800"))
```

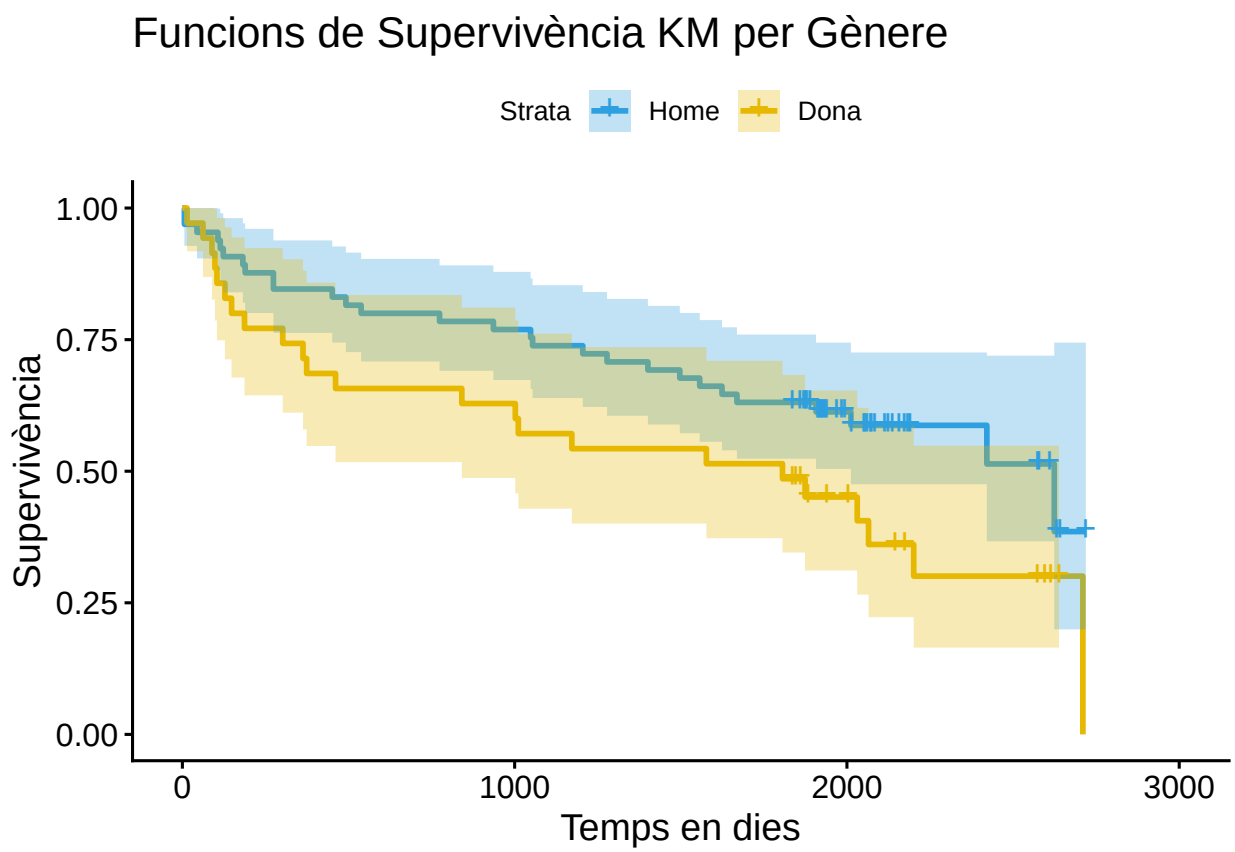

Per comprovar quin mètode és més adequat entre el model exponencial i el model de Weibull, s'utilitza la gràfica de la combinació lineal dels logaritmes de la funció de supervivència pròpia de la distribució de Weibull. Aquest criteri es basa en la linealitat de la corba: si la representació és aproximadament lineal, el model de Weibull es considera adequat. A més, si la pendent és propera a 1, també es pot considerar adequat el model exponencial, ja que aquest constitueix un cas particular del model de Weibull.

La transformació lineal de la funció de supervivència $S(t)$ en l'escala Weibull s'expressa com:

$$\log\big(-\log(S(t))\big) = \log(\lambda) + p\log(t)$$

Això implica:

- Si la relació $\log(-\log(S(t)))$ vs $\log(t)$ és lineal, la distribució és **Weibull**.
- Si la pendent $p \approx 1$, la distribució és **Exponencial**.

Els dos gràfics serveixen per avaluar l'adequació del supòsit de riscos proporcionals i la distribució de Weibull. En el primer cas de corbes log-log per gènere, si el supòsit de riscos proporcionals es complís, les corbes de Home i Dona haurien de ser aproximadament paral · leles al llarg del temps.

```
par(mfrow = c(1, 2))
plot(km.gender, fun = "cloglog",
     xlab = "Log(Temps en dies)", ylab = "log(-log(S(t)))",
     lty = c(1, 3), col = c("blue", "red"))
legend("topleft", c("Home", "Dona"), lty = c(1, 3), col = c("blue", "red"))
title("Corbes log-log per Gènere")

plot(log(km.gender$time),log(-log(km.gender$surv)))
```

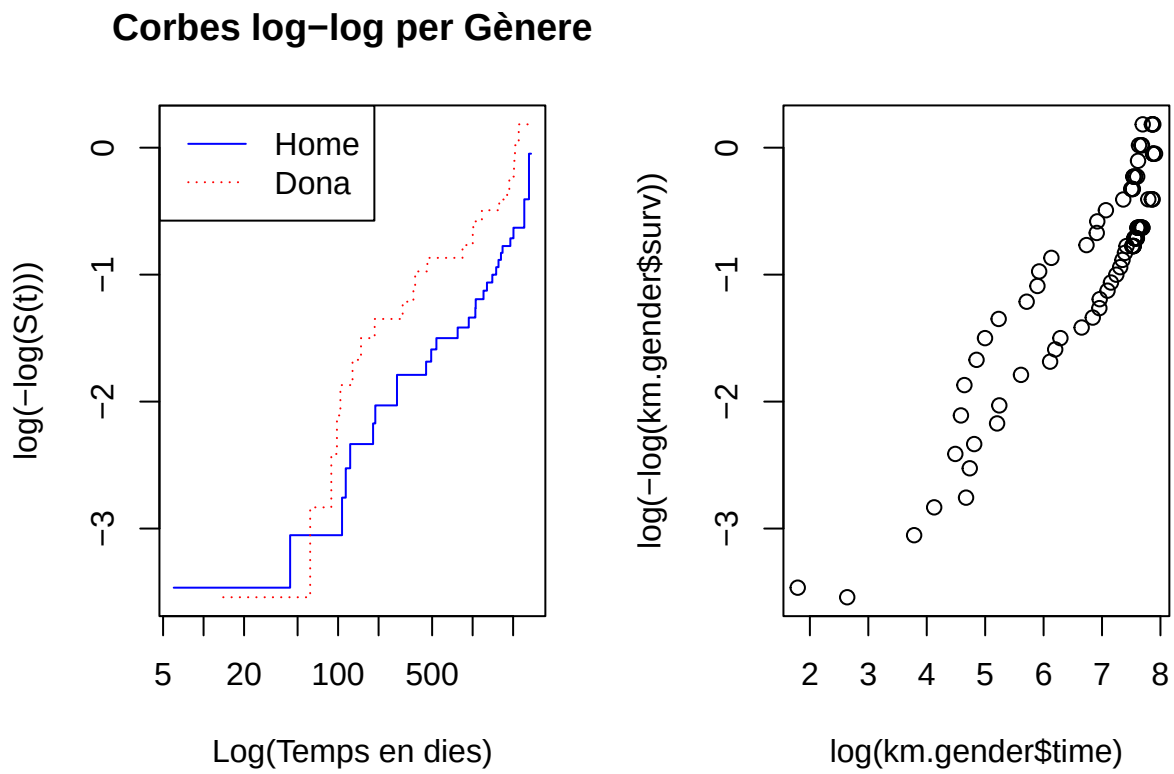

S'observa, però, que les dues corbes comencen molt properes i es van separant progressivament a mesura que avança el temps, amb la corba de la Dona per sobre implicant un risc acumulat major als dels homes, la qual cosa suggereix una **possible violació del supòsit de proporcionalitat**, o almenys que l'efecte del gènere no és constant en el temps.

Pel que fa al segón gràfic que indica el mateix però amb punts, si les dades seguissin una distribució de Weibull, **els punts haurien de disposar-se al voltant d'una línia recta**; en canvi, s'aprecia una corba amb forma no del tot lineal, especialment als extrems, cosa que qüestiona l'ajust d'un model paramètric de Weibull pur. Considerant que les rectes no semblen ser paraleles, tenint en complte la probabilitat de l'incompliment de la proporció AFT i PH, no obstant, la millor distribució seria per ara la Weibull on amb eines gràfiques no queda tot clar.

```
# Índexs de cada grup
n_homes   <- km.gender$strata[1]
n_dones   <- km.gender$strata[2]
idx_homes <- 1:n_homes
idx_dones <- (n_homes + 1):(n_homes + n_dones)

# Homes (gender=0)
surv_homes  <- km.gender$surv[idx_homes]
time_homes  <- km.gender$time[idx_homes]
valid_homes <- surv_homes > 0 & surv_homes < 1

summary(lm(log(-log(surv_homes[valid_homes])) ~
           log(time_homes[valid_homes])))
```

```
##
```

```
## Call:
## lm(formula = log(-log(surv_homes[valid_homes])) ~ log(time_homes[valid_homes]))
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.34978 -0.07153 -0.02329  0.01680  0.65397
##
## Coefficients:
##                              Estimate Std. Error t value Pr(>|t|)
## (Intercept)                  -5.18489    0.13661  -37.95   <2e-16 ***
## log(time_homes[valid_homes])  0.59454    0.01905   31.21   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.1714 on 60 degrees of freedom
## Multiple R-squared:  0.942,  Adjusted R-squared:  0.941
## F-statistic:   974 on 1 and 60 DF,  p-value: < 2.2e-16
```

```r
# Dones (gender=1)
surv_dones  <- km.gender$surv[idx_dones]
time_dones  <- km.gender$time[idx_dones]
valid_dones <- surv_dones > 0 & surv_dones < 1

summary(lm(log(-log(surv_dones[valid_dones])) ~
           log(time_dones[valid_dones])))
```

```
##
## Call:
## lm(formula = log(-log(surv_dones[valid_dones])) ~ log(time_dones[valid_dones]))
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.44875 -0.13209 -0.02345  0.12301  0.31050
##
## Coefficients:
##                              Estimate Std. Error t value Pr(>|t|)
## (Intercept)                   -5.1056     0.1516  -33.68   <2e-16 ***
## log(time_dones[valid_dones])   0.6594     0.0225   29.30   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.1796 on 32 degrees of freedom
## Multiple R-squared:  0.9641, Adjusted R-squared:  0.963
## F-statistic: 858.8 on 1 and 32 DF,  p-value: < 2.2e-16
```

Els R^2 de tots dos grups són molt elevats, indicant que la relació entre $\ln(-\ln S(t))$ i $\ln(t)$ és clarament lineal, cosa que no s'apreciaba correctament gràficament. Per tant, la distribució Weibull s'ajusta bé a les dades dels dos grups. Entre exponencial i Weibull, la distribució de Weibull sembla ser més justa.

Grup	Pendent (p)	R^2
Homes	0.595	0.942
Dones	0.659	0.964

Als tenir dos pendents clarament inferiors a 1, implica que **la distribució Weibull és preferible a**

l'Exponencial, que requeriria $p = 1$.

A més, els dos pendents són similars entre si, cosa que suggereix que els dos grups comparteixen el mateix paràmetre p. Això implica que es pot assumir la hipòtesi de riscos proporcionals, el hazard ratio entre homes i dones és constant al llarg del temps.

En resum, les dades s'ajusten a un **model Weibull** amb riscos proporcionals, que és alhora un model AFT i PH, la qual cosa facilita la interpretació tant en termes de factors d'acceleració com de hazard ratios.

Després de poder comparar les distribucions de Weibull i Exponencial tenim en compte la possibilitat de la log-logistic, una de les més complexes. Igual que en el cas de la distribució de Weibull, aquesta també podem veure una relació lineal amb els logaritmes.

```
plot(log(km.gender$time),
     log(km.gender$surv / (1 - km.gender$surv)),
     xlab = "Log(Temps en dies)", ylab = "Log(Survival Odds)",
     col = ifelse(km.gender$strata == "gender=0", "blue", "red"), pch = 16)
title("Corbes log(SO) per Gènere")
```

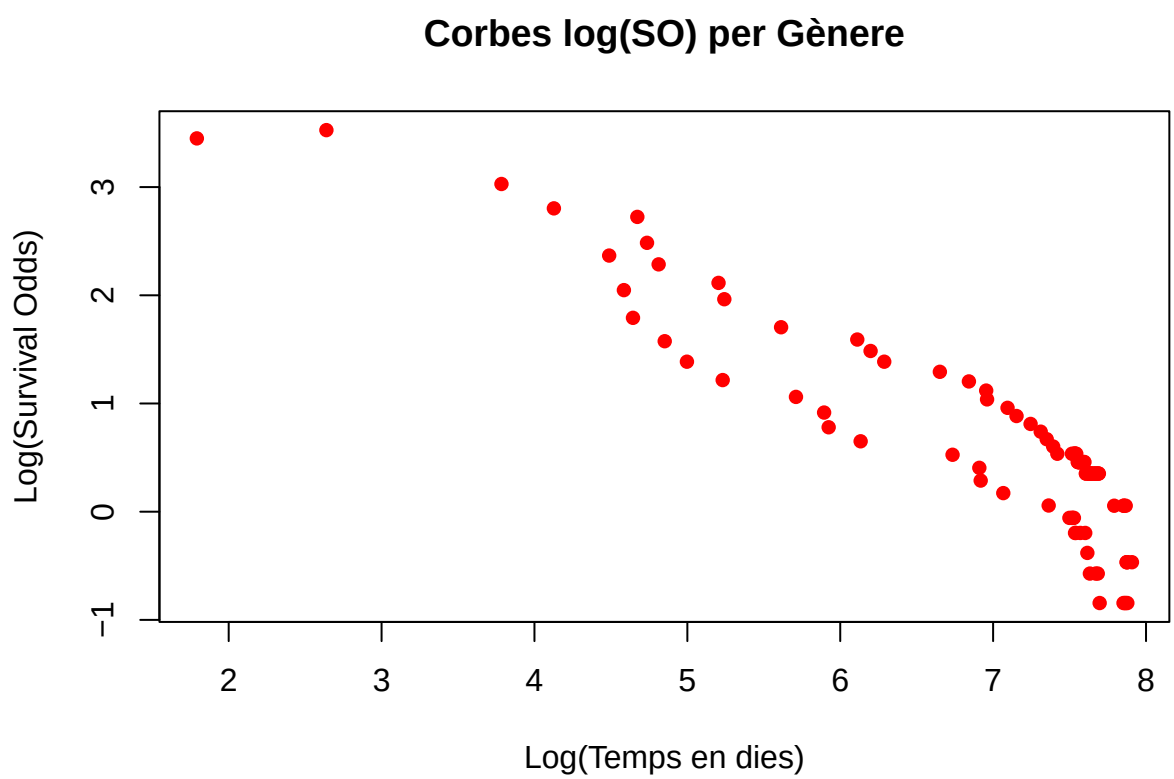

El gràfic del logaritme dels odds de supervivència versus $\ln(t)$ mostra dues bandes clarament separades, corresponents als dos grups de gènere. Tot i que s'observa una tendència descendent aproximadament lineal, les dues bandes no són perfectament paral · leles i presenten certa curvatura als extrems. Això suggereix que la distribució log-logística pot no ser la millor opció comparant amb la Weibull i que la hipòtesi d'odds proporcionals no es compleix de manera clara.

En conjunt, amb eines gràfiques sembla que la millor distribució és Weibull, més adequat per a aquestes dades, mentre que el model log-logístic presenta un ajust menys satisfactori.

Models

A continuació, s'ajusten diferents models segons les tres distribucions possibles per a la variable gènere, amb l'objectiu de determinar amb precisió quina s'adapta millor a les dades. Per fer-ho, s'empren dos criteris de selecció: el p-valor i el criteri d'informació d'Akaike (AIC), on un valor menor d'aquest últim indica un millor ajust del model.

Exponencial

El **model exponencial** assumeix una **taxa de risc constant** (p = 1) i **riscos proporcionals** entre grups.

```
m.exp <- survreg(surv.whas ~ gender, dist = "exponential", data = data)
summary(m.exp)
```

```
##
## Call:
## survreg(formula = surv.whas ~ gender, data = data, dist = "exponential")
##              Value Std. Error     z      p
## (Intercept)  8.218      0.189 43.49 <2e-16
## gender      -0.602      0.281 -2.14  0.033
##
## Scale fixed at 1
##
## Exponential distribution
## Loglik(model)= -456.3   Loglik(intercept only)= -458.5
##  Chisq= 4.42 on 1 degrees of freedom, p= 0.036
## Number of Newton-Raphson Iterations: 5
## n= 100
```

```
extractAIC(m.exp)
```

```
## [1]   2.0000 916.5779
```

En el model de supervivència paramètric exponencial, la variable **gènere** té un **efecte significatiu** sobre el temps de supervivència p = 0,033. Com que el coeficient de gender és negatiu, -0,602, el grup *dones* presenta un temps de supervivència menor que el grup de referència, és a dir, la mort es produeix abans en aquest grup.

Weibull

El model de **Weibull** generalitza l'exponencial permetent una **taxa de risc monòtona creixent o decreixent** segons el valor del paràmetre de forma p.

```
m.weib <- survreg(surv.whas ~ gender, dist = "weibull", data = data)
summary(m.weib)
```

```
##
## Call:
## survreg(formula = surv.whas ~ gender, data = data, dist = "weibull")
##              Value Std. Error     z      p
## (Intercept)  8.464      0.284 29.76 <2e-16
## gender      -0.790      0.391 -2.02  0.043
## Log(scale)   0.303      0.128  2.36  0.018
##
## Scale= 1.35
##
## Weibull distribution
## Loglik(model)= -453.2   Loglik(intercept only)= -455.3
```

```
##  Chisq= 4.16 on 1 degrees of freedom, p= 0.041
## Number of Newton-Raphson Iterations: 5
## n= 100
```

```r
extractAIC(m.weib)
```

```
## [1]   3.000 912.342
```

En el model de supervivència paramètric Weibull, la variable **gènere** també té un **efecte significatiu** sobre el temps de supervivència p = 0,043. Com que el coeficient de gender és negatiu (-0,790), el grup *dones* presenta un temps de supervivència més curt que el grup de referència, és a dir, l'esdeveniment tendeix a produir-se abans en aquest grup.

Exponencial vs Weibull

$$H_0 : p = 1 \qquad \text{vs} \qquad H_1 : p \neq 1$$

```r
summary(m.weib)$table
```

```
##                  Value Std. Error        z             p
## (Intercept)  8.4637267  0.2844093 29.75896 1.327777e-194
## gender      -0.7904360  0.3914775 -2.01911  4.347583e-02
## Log(scale)   0.3033633  0.1284480  2.36176  1.818842e-02
```

En el model de supervivència paramètric Weibull, la variable **gènere** té un efecte estadísticament significatiu sobre el temps de supervivència (p = 0,0435). Com que el coeficient de gender és negatiu (-0,7904), el grup *dones* un temps de supervivència inferior al del grup de referència, és a dir, l'esdeveniment es produeix abans en aquest grup. A més, el paràmetre Log(scale) = 0,3034 és significatiu (p = 0,0182), cosa que indica que el paràmetre d'escala del model és diferent d'1 i, per tant, **el model Weibull és més adequat que l'exponencial**, ja que no assumeix una taxa de risc constant.

Log-logistic

El model log-logístic permet una taxa de risc no monòtona, podent créixer inicialment i després decréixer, cosa que l'exponencial i el Weibull no poden capturar.

```r
m.loglog <- survreg(surv.whas ~ gender, dist = "loglogistic", data = data)
summary(m.loglog)
```

```
##
## Call:
## survreg(formula = surv.whas ~ gender, data = data, dist = "loglogistic")
##              Value Std. Error     z      p
## (Intercept)  8.048      0.296 27.16 <2e-16
## gender      -0.901      0.455 -1.98  0.048
## Log(scale)   0.165      0.123  1.34  0.179
##
## Scale= 1.18
##
## Log logistic distribution
## Loglik(model)= -454.4   Loglik(intercept only)= -456.4
##  Chisq= 3.96 on 1 degrees of freedom, p= 0.047
## Number of Newton-Raphson Iterations: 4
## n= 100
```

```r
extractAIC(m.loglog)
```

```
## [1]   3.000 914.778
```

En el model de supervivència paramètric log-logístic, la variable gènere té un efecte significatiu sobre el temps de supervivència. Com que el coeficient de gender és negatiu, el grup *dones* presenta un temps de supervivència més curt que el grup de referència, és a dir, l'esdeveniment tendeix a produir-se abans en aquest grup. A més, el contrast global del model (p = 0,047) indica que incloure el gènere millora significativament l'ajust respecte al model sense covariables.

Hipòtesis dels models i criteris de validació

```r
cat("\n--- Comparació AIC (model amb gender) ---\n")
```

```
##
## --- Comparació AIC (model amb gender) ---
```

```r
cat("Exponencial: ", extractAIC(m.exp)[2], "\n")
```

```
## Exponencial:  916.5779
```

```r
cat("Weibull:     ", extractAIC(m.weib)[2], "\n")
```

```
## Weibull:      912.342
```

```r
cat("Log-logístic:", extractAIC(m.loglog)[2], "\n")
```

```
## Log-logístic: 914.778
```

Tot i que els resultats son força igualats, **la distribució Weibull és la millor en termes d'AIC.**

```r
 # Test versemblança Exponencial vs Weibull
(chisq.exp.weib <- -2 * (m.exp$loglik[2] - m.weib$loglik[2]))
```

```
## [1] 6.235906
```

```r
1 - pchisq(chisq.exp.weib, df = 1)
```

```
## [1] 0.01251855
```

El test de versemblança rebutja el model exponencial en favor del Weibull (p-valor = 0.013), indicant que **la taxa de risc no és constant al llarg del temps.**

Comparació amb els parametres de kapkan meier, per veure com de semblant son els valors.

```r
# Models
m.exp    <- survreg(surv.whas ~ gender, dist = "exponential",  data = data)
m.weib   <- survreg(surv.whas ~ gender, dist = "weibull",      data = data)
m.loglog <- survreg(surv.whas ~ gender, dist = "loglogistic",  data = data)

# Patrons i percentils
pattern0 <- data.frame(gender = 0)
pattern1 <- data.frame(gender = 1)
pct2     <- 0:100 / 100
survival <- 1 - pct2

# Prediccions dels tres models
days0.exp    <- predict(m.exp,    newdata = pattern0, type = "quantile", p = pct2)
days1.exp    <- predict(m.exp,    newdata = pattern1, type = "quantile", p = pct2)
days0.weib   <- predict(m.weib,   newdata = pattern0, type = "quantile", p = pct2)
days1.weib   <- predict(m.weib,   newdata = pattern1, type = "quantile", p = pct2)
days0.loglog <- predict(m.loglog, newdata = pattern0, type = "quantile", p = pct2)
days1.loglog <- predict(m.loglog, newdata = pattern1, type = "quantile", p = pct2)
```

```r
#Plot 1: Exponencial
plot(km.gender, xlab = "Temps en dies", ylab = "Supervivència",
     lty = c(1, 3), col = c("blue", "red"),
     main = "Exponencial vs KM")
points(days0.exp, survival, pch = 21, col = "blue")
points(days1.exp, survival, pch = 16, col = "red")
legend("topright",
       c("KM Home", "KM Dona", "Exp. Home", "Exp. Dona"),
       lty = c(1, 3, NA, NA), pch = c(NA, NA, 21, 16),
       col = c("blue", "red", "blue", "red"), cex = 0.8)
```

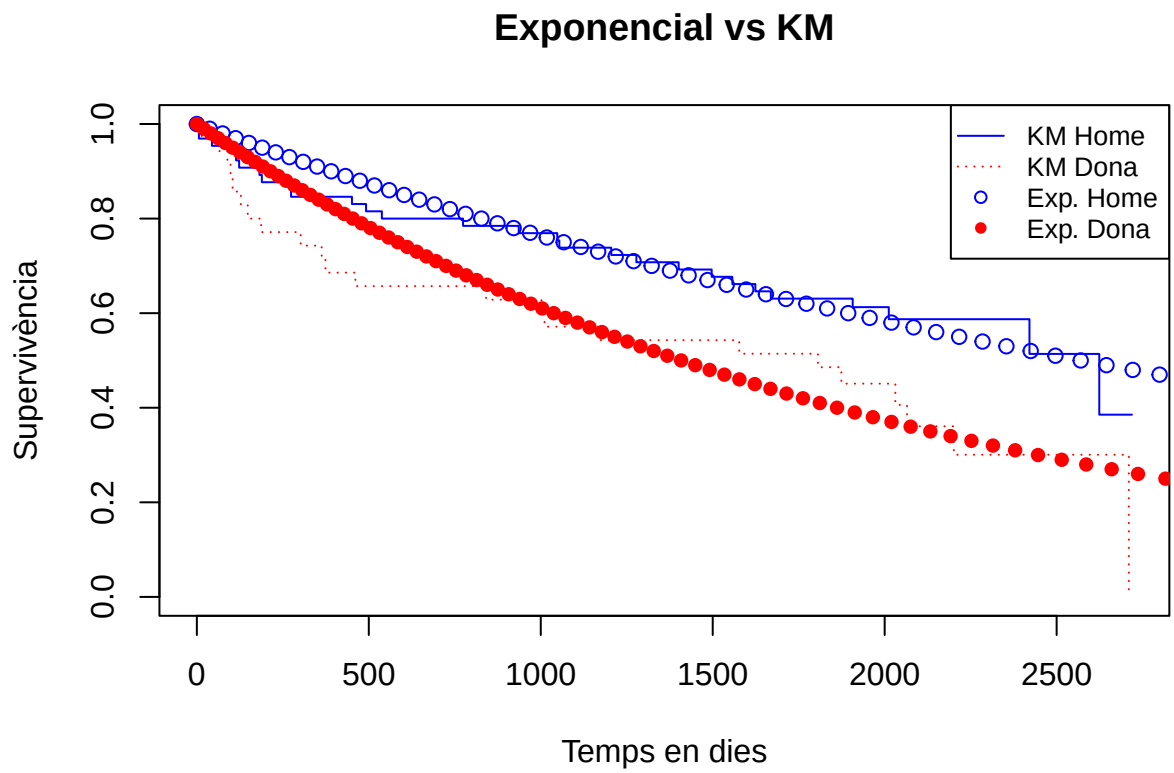


```r
# Plot 2: Weibull
plot(km.gender, xlab = "Temps en dies", ylab = "Supervivència",
     lty = c(1, 3), col = c("purple", "green"),
     main = "Weibull vs KM")
points(days0.weib, survival, pch = 21, col = "purple")
points(days1.weib, survival, pch = 16, col = "green")
legend("topright",
       c("KM Home", "KM Dona", "Weibull Home", "Weibull Dona"),
       lty = c(1, 3, NA, NA), pch = c(NA, NA, 21, 16),
       col = c("purple", "green", "purple", "green"), cex = 0.8)
```

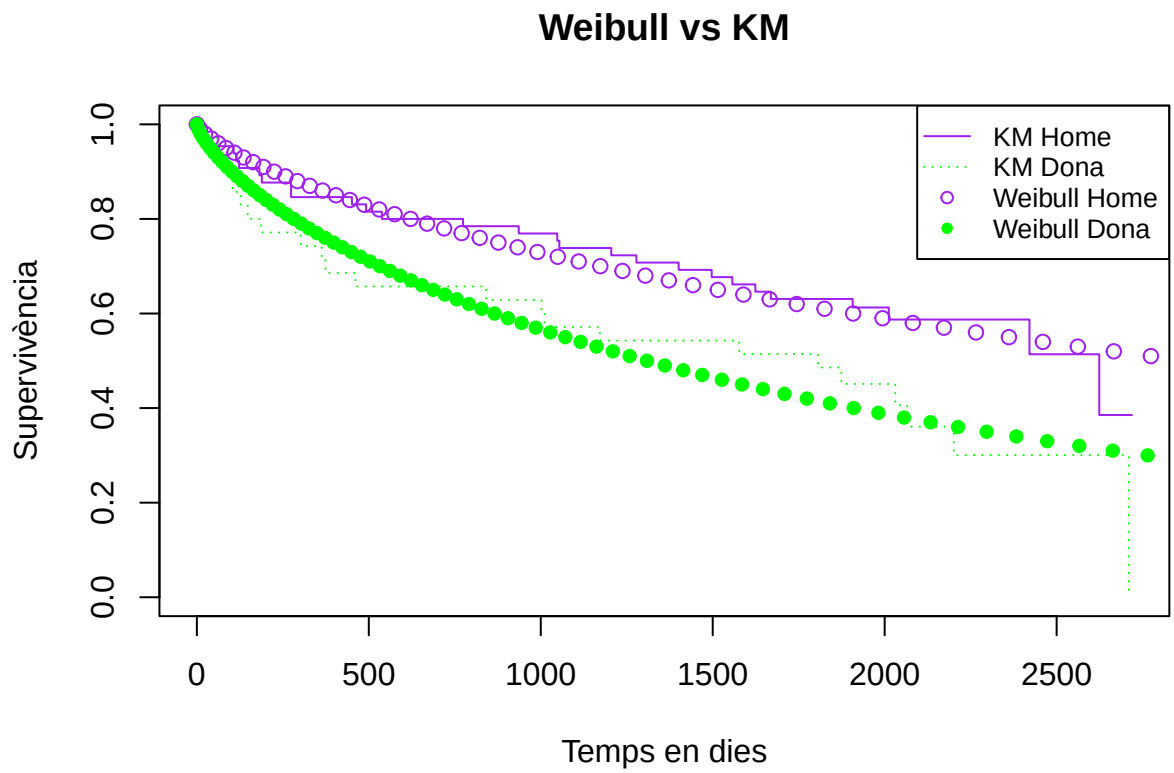


```r
# Plot 3: Log-logístic
plot(km.gender, xlab = "Temps en dies", ylab = "Supervivència",
     lty = c(1, 3), col = c("skyblue", "orange"),
     main = "Log-logístic vs KM")
points(days0.loglog, survival, pch = 21, col = "skyblue")
points(days1.loglog, survival, pch = 16, col = "orange")
legend("topright",
       c("KM Home", "KM Dona", "Log-log. Home", "Log-log. Dona"),
       lty = c(1, 3, NA, NA), pch = c(NA, NA, 21, 16),
       col = c("skyblue", "orange", "skyblue", "orange"), cex = 0.8)
```

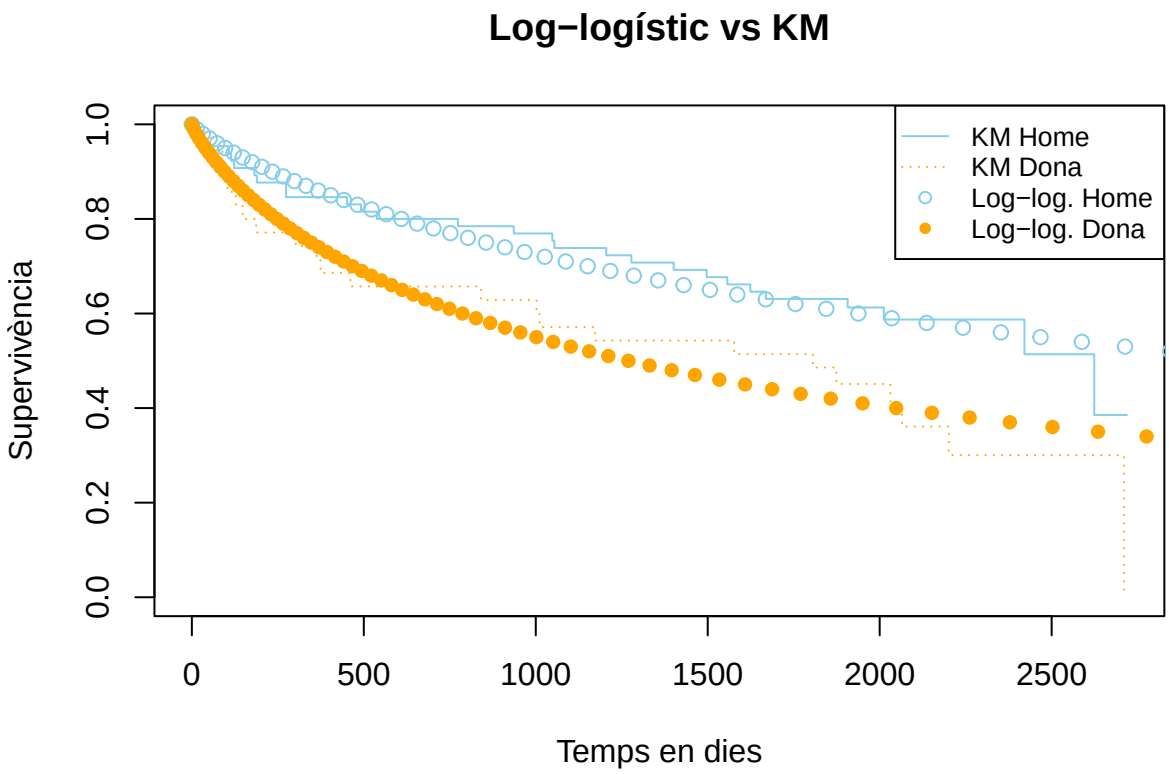

El gràfic mostra que el model Weibull s'ajusta força bé a les corbes de Kaplan-Meier per a tots dos grups, ja que segueix bastant de prop la tendència observada de la supervivència. A més, s'observa clarament que els homes presenten una supervivència més alta que les dones al llarg del temps, fet coherent amb el coeficient negatiu de la variable gender en el model.

Evidència del compliment de les hipòtesis

Hipòtesi AFT : El gràfic log-log mostra una relació clarament lineal entre $\ln(-\ln S(t))$ i $\ln(t)$ per als dos grups, amb R^2 de 0.942 (homes) i 0.964 (dones). Això confirma el compliment de la hipòtesi AFT, que és compatible tant amb el model Weibull com amb l'Exponencial i el log-logístic.

Hipòtesi PH: Les dues rectes del gràfic log-log presenten pendents similars com s'ha calculat anteriorment i aproximadament paral · lels, cosa que recolza el compliment de la hipòtesi de riscos proporcionals. Això implica que el hazard ratio entre homes i dones es manté constant al llarg del temps.

Hipòtesi PO: El gràfic log(SO) mostra dues bandes que no són perfectament paral · leles i presenten certa curvatura, especialment als extrems. Això indica que la hipòtesi PO, pròpia del model log-logístic, no es compleix de manera massa.

Criteris de validació dels models

Per seleccionar el millor model paramètric disposem dels criteris següents:

- **Gràfics de validació**: el gràfic log-log valida l'ajust Weibull i la hipòtesi PH, mentre que el gràfic log(SO) valida l'ajust log-logístic i la hipòtesi PO, comentats anteriorment.
- **Test Log(scale)**: contrasta si $p = 1$ (model Exponencial) o $p \neq 1$ (model Weibull). Un p-valor inferior a 0.05 implica que el model Weibull millora l'Exponencial.

- **AIC**: penalitza la complexitat del model; un valor menor indica millor ajust.
- **Test de raó de versemblança (LRT)**: compara models imbricats, com ara l'Exponencial (cas particular del Weibull amb $p = 1$) versus el Weibull.

Model	AIC	Log(scale) p-valor	Hipòtesis
Exponencial	916.5779	–	Només AFT i PH ($p = 1$)
Weibull	912.342	0.018	AFT i PH ($p \neq 1$)
Log-logístic	914.778	0.179	AFT i PO

El **model Weibull** és el més adequat pels motius següents:

- Els pendents del gràfic log-log (0.595 i 0.659) són clarament inferiors a 1, descartant el model Exponencial.
- El test sobre Log(scale) és significatiu, confirmant que $p \neq 1$.
- Presenta l'AIC més baix dels tres models.
- El gràfic log(SO) no dóna suport al model log-logístic.
- És l'únic model que compleix alhora les hipòtesis **AFT i PH**, facilitant la interpretació tant en termes de factors d'acceleració com de hazard ratios.

Interpretació model

Després d'escollir la distribució com la weibull, estudiarem diferents aspectes del model:

Paràmetre escala

Per modelitzar el temps fins a l'esdeveniment s'ha ajustat un model amb la distribució de Weibull com hem comentat anteriorment. Aquest model permet estimar el paràmetre d'escala p, que caracteritza la forma de la funció de risc i determina si aquest és creixent, decreixent o constant al llarg del temps.

```r
cat("Escala (1/p):", m.weib$scale, "\n")
```

```
## Escala (1/p): 1.354406
```

```r
cat("p =", 1 / m.weib$scale, "\n")
```

```
## p = 0.7383308
```

Segons el resultat del valor d'escala, una estimació del paràmetre obtinguda és $\frac{1}{p} = 1.3544$, la qual cosa correspon a un valor de p = 0.7383. Com que p < 1, això indica que la funció de risc és decreixent amb el temps, implicant que la probabilitat de que es produeixi la mort després d'un atac de cor agut és més alta a l'inici del seguiment i disminueix progressivament a mesura que avança el temps.

Factor d'acceleració (AFT)

El factor d'acceleració (AF) descriu l'estirament o la contracció de les funcions de supervivència quan es compara un grup amb un altre. Així doncs quantifica en quina mesura el temps fins a l'esdeveniment es estirat segons els sexe dels individus, dones respecte a homes.

```r
FA.gender <- exp(m.weib$coef[2])
IC.FA <- c(exp(m.weib$coef[2] - 1.96 * sqrt(m.weib$var[2, 2])),
           exp(m.weib$coef[2] + 1.96 * sqrt(m.weib$var[2, 2])))
cat("\nFactor d'Acceleració (FA) Dona vs Home:\n")
```

```
##
## Factor d'Acceleració (FA) Dona vs Home:
```

```r
cat("FA =", FA.gender, "\n")
```

```
## FA = 0.4536469
```

```r
cat("IC 95%: [", IC.FA[1], ",", IC.FA[2], "]\n")
```

```
## IC 95%: [ 0.2106132 , 0.9771256 ]
```

Pel que fa al grup de les dones respcte als homes, els seu factor d'acceleració és de $\gamma = 0.454$ (IC 95%: [0.211, 0.977]). Com que s'ha obtingut un valor de γ inferior a 1 indica que el temps fins a l'esdeveniment és més curt en les dones tenint una supervivencia inferior. Concretament, el temps esperat en dones és aproximadament un 54.6% inferior al dels homes. Atès que l'interval de confiança no inclou l'1, aquesta diferència és estadísticament significativa al nivell del 5%.

Hazard Ratio (PH) per Weibull

La relació entre el *hazard ratio* (HR) i el factor d'acceleració (AF) en el model de Weibull és:

$$HR = \left(\frac{1}{AF}\right)^p = \exp\left(-\frac{\alpha_1}{\text{scale}}\right)$$

on p és el paràmetre de forma del model.

L'assumpció subjacent és que l'efecte de les covariables és **multiplicatiu (proporcional)** respecte de la funció de risc:

$$h(t \mid X) = h_0(t) \cdot \exp(\beta' X) = h_0(t) \cdot \theta, \quad \forall t \geq 0$$

on:

- $\beta' = (\beta_1, \ldots, \beta_p)$: coeficients de regressió,
- $h_0(t) = h(t \mid X = 0)$: funció de risc basal,
- θ: *hazard ratio*.

El *hazard ratio* mesura el canvi d'escala en la funció de risc causat per les covariables.

Igual que el factor d'acceleració, el *hazard ratio* és constant al llarg del temps.

```r
HR.gender <- exp(-m.weib$coef[2] / m.weib$scale)
cat("\nHazard Ratio (HR) Dona vs Home:\n")
```

```
##
## Hazard Ratio (HR) Dona vs Home:
```

```r
cat("HR =", HR.gender, "\n")
```

```
## HR = 1.792486
```

El Hazard Ratio obtingut per a dones respecte a homes és de $\theta = 1.792$, la qual cosa indica que les dones presenten un risc d'experimentar l'esdeveniment aproximadament un 79.2% superior al dels homes durant tot el seguiment del estudi. Ixí doncs, el resulat és consistent amb el $\gamma < 1$ obtingut anteriorment, concluint que les dones arriben a l'esdeveniment de forma més ràpida.

Per tal de quantificar les diferències entre grups de manera més interpretable, s'han estimat els percentils (25, 50, 75) del temps de supervivència per a homes i dones per separat.

```r
# Medianes per cada grup
pct <- c(0.25, 0.50, 0.75)
medianes <- cbind(pct,
                  predict(m.weib, newdata = pattern0, type = "quantile", p = pct),
                  predict(m.weib, newdata = pattern1, type = "quantile", p = pct))
colnames(medianes) <- c("Percentil", "Home", "Dona")
cat("\nPercentils del temps de supervivència:\n")
```

```
##
## Percentils del temps de supervivència:
```

```r
print(medianes)
```

```
##      Percentil      Home      Dona
## [1,]      0.25  876.7945  397.7551
## [2,]      0.50 2885.1127 1308.8226
## [3,]      0.75 7376.9993 3346.5532
```

El temps medià de supervivència és de 2885 dies en homes i de 1309 dies en dones, el que representa que les dones assoleixen la meitat dels esdeveniments gairebé en la meitat del temps que els homes com hem observat anteriorment en el s apartats anteriors a aquest.

La tendència es manté de forma consistent als percentils 25 i 75, on les diferències entre grups són igualment notables, reforçant la conclusió que el gènere és un factor pronòstic rellevant en aquest model.

Relacions & Coherències

Per validar els resultats obtinguts amb el model de Weibull, es compara amb el test log-rank no paramètric, i amb el test de raó de versemblança (LRT) derivat del propi model.

```r
# Coherència amb test log-rank
test.logrank <- survdiff(surv.whas ~ gender, data = data)
test.logrank
```

```
## Call:
## survdiff(formula = surv.whas ~ gender, data = data)
##
##           N Observed Expected (O-E)^2/E (O-E)^2/V
## gender=0 65       28     34.6      1.27      3.97
## gender=1 35       23     16.4      2.68      3.97
##
##  Chisq= 4  on 1 degrees of freedom, p= 0.05
```

```r
# Relació LRT model vs LR test
(chisq.lrt <- -2 * (m.weib$loglik[1] - m.weib$loglik[2]))
```

```
## [1] 4.159469
```

```r
1 - pchisq(chisq.lrt, df = 1)
```

```
## [1] 0.04140237
```

El test log-rank proporciona un estadístic de $\chi^2 = 4$ (p = 0.046), mentre que el LRT del model de Weibull dona un valor de $\chi^2 = 4.159$ (p = 0.041). Tots dos tests apunten en la mateixa direcció: existeix una diferència estadísticament significativa entre homes i dones en el temps fins a l'esdeveniment, al nivell de significació del 5%.

La coherència entre ambdós resultats reforça la robustesa de les conclusions obtingudes: el gènere és una covariable amb un efecte significatiu sobre la supervivència.

Anàlisi amb variables

Variable Age

```
# Gràfic log-log per validar Weibull estratificant per fage
km.fage <- survfit(surv.whas ~ fage, data = data)
plot(km.fage, fun = "cloglog",
     xlab = "Log(Temps en dies)", ylab = "log-log Supervivència",
     lty = c(1, 3))
legend("topleft", c("<70", "70+"), lty = c(1, 3))
title("Corbes log-log per fage")
```

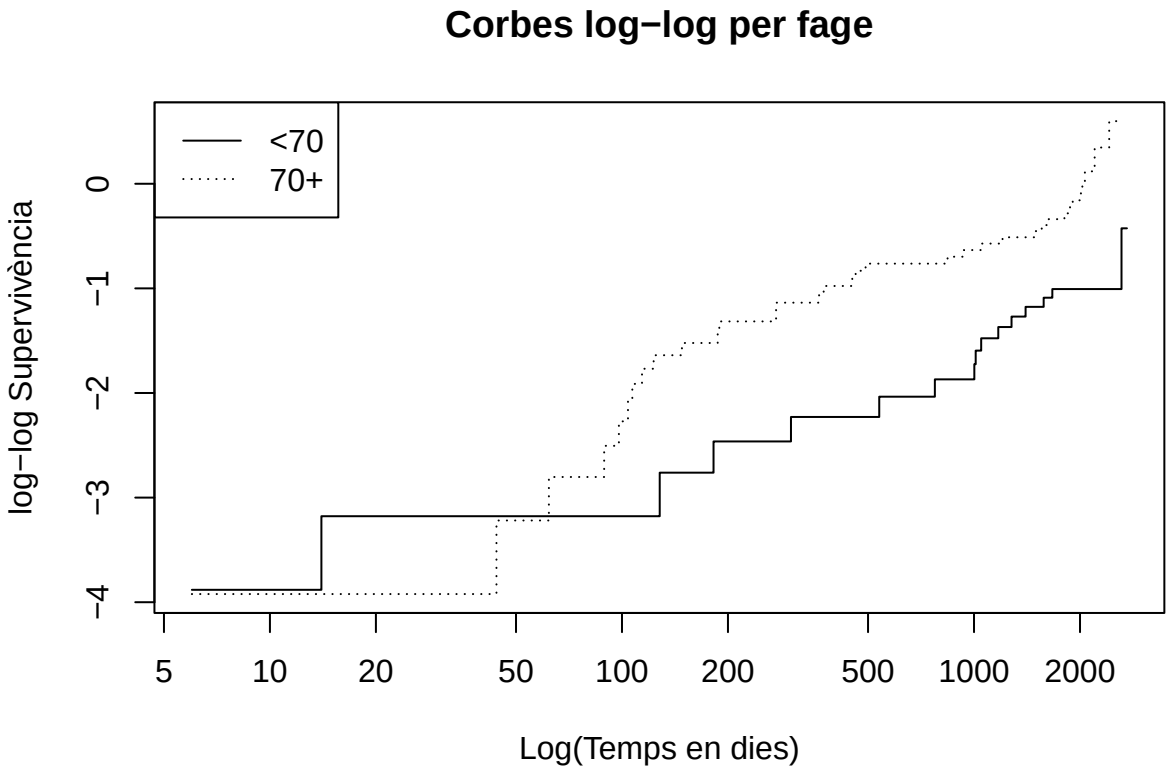

Malgrat que les corbes log-log **no mostren una linealitat ni un paral · lelisme perfectes**, especialment als extrems de la distribució temporal, el model de Weibull havia estat seleccionat prèviament com el millor model paramètric per a aquestes dades en base a criteris d'AIC i al test de versemblança enfront del model exponencial. Per aquest motiu, es continua l'anàlisi incorporant les covariables fage i fbmi dins del marc del model de Weibull, assumint que les desviacions observades gràficament no comprometen de manera rellevant les conclusions del model.

Construcció del model incloent les variables **gènere i fage**:

```
m.weib.age <- survreg(surv.whas ~ gender + fage, dist = "weibull", data = data)
summary(m.weib.age)
```

```
##
## Call:
## survreg(formula = surv.whas ~ gender + fage, data = data, dist = "weibull")
##               Value Std. Error     z      p
```

```
## (Intercept)  9.013      0.392 23.01 <2e-16
## gender      -0.421      0.390 -1.08  0.280
## fage        -1.251      0.435 -2.87  0.004
## Log(scale)   0.280      0.127  2.20  0.028
##
## Scale= 1.32
##
## Weibull distribution
## Loglik(model)= -448.3   Loglik(intercept only)= -455.3
##  Chisq= 13.92 on 2 degrees of freedom, p= 0.00095
## Number of Newton-Raphson Iterations: 5
## n= 100
```

```r
m.weib.age$scale
```

```
## [1] 1.322672
```

```r
1 / m.weib.age$scale
```

```
## [1] 0.7560456
```

El model de **Weibull** ajustat per **gènere** i **edat** mostra que **l'edat és un confusor parcial de l'efecte del gènere**. El coeficient de fage és significatiu ($p = 0.004$), indicant que els pacients majors de 70 anys presenten un temps de supervivència significativament menor. En canvi, **el coeficient de gender deixa de ser significatiu ($p = 0.280$) un cop s'ajusta per l'edat**, cosa que suggereix que part de **la diferència observada entre homes i dones** en el model simple era **deguda a la distribució diferencial de l'edat** entre els dos grups.

El paràmetre d'escala ($1/p = 1.32$, $p > 1$) confirma que **la taxa de risc és creixent** al llarg del temps, cosa que valida l'ús del model de **Weibull** per sobre de l'exponencial. El test global del model és significatiu ($p < 0.001$), indicant que el conjunt de variables incloses millora l'ajust respecte al model nul.

```r
# LRT vs model amb només gender
(chisq.age2 <- -2 * (m.weib$loglik[2] - m.weib.age$loglik[2]))
```

```
## [1] 9.76367
```

```r
1 - pchisq(chisq.age2, df = 1)
```

```
## [1] 0.001779942
```

El test de versemblança entre el model amb només gender i el model que incorpora fage és significatiu (estadístic = 9.76, p-valor = 0.002), indicant que **afegir l'edat millora significativament l'ajust del model**. Per tant, fage és una variable rellevant que contribueix a explicar el temps de supervivència més enllà de l'efecte del gènere.

```r
#comparació d'AIC incloent o no fage
extractAIC(m.weib)
```

```
## [1]   3.000 912.342
```

```r
extractAIC(m.weib.age)
```

```
## [1]   4.0000 904.5783
```

L'AIC del model amb gender i fage (904.58) és inferior al del model amb només gender (912.34), confirmant que la inclusió de l'edat millora l'ajust del model penalitzant per complexitat. Aquest resultat és coherent amb el test de versemblança i reforça la decisió d'incloure fage com a covariable.

```r
# FA i HR (gender ajustat per fage)
exp(m.weib.age$coef[2])
```

```
##    gender
## 0.6563083
```

```r
c(exp(m.weib.age$coef[2] - 1.96 * sqrt(m.weib.age$var[2, 2])),
  exp(m.weib.age$coef[2] + 1.96 * sqrt(m.weib.age$var[2, 2])))
```

```
##    gender    gender
## 0.3054842 1.4100255
```

```r
exp(-m.weib.age$coef[2] / m.weib.age$scale)
```

```
##   gender
## 1.374912
```

El factor d'acceleració (FA) de les dones respecte dels homes, ajustat per edat, és de 0.66 (IC 95%: 0.31 – 1.41). Com que **l'interval de confiança conté l'1**, no podem considerar que l'efecte del gènere sigui estadísticament significatiu un cop controlada l'edat, cosa coherent amb el p-valor de 0.280 observat al summary del model.

En termes de **hazard ratio (HR)**, les dones presenten un risc instantani de mort 1.37 vegades superior al dels homes ajustat per edat, tot i que **aquest efecte tampoc és significatiu**. Això indica que **l'edat actua com a confusor parcial de la relació entre gènere i supervivència**.

```r
# Percentils i gràfic
patern1 <- data.frame(gender = "Dona", fage = 0)
pct <- c(.25, .50, .75)
pattern0 <- data.frame(gender = factor("Home", levels = c("Home", "Dona")), fage = 0)
pattern1 <- data.frame(gender = factor("Dona", levels = c("Home", "Dona")), fage = 0)


pct2     <- 0:100 / 100
survival <- 1 - pct2
days0 <- predict(m.weib.age, newdata = pattern0, type = "quantile", p = pct2)
days1 <- predict(m.weib.age, newdata = pattern1, type = "quantile", p = pct2)

plot(km.gender, xlab = "Temps en dies", ylab = "Supervivència",
     lty = c(1, 3), col = c("blue", "red"),
     main = "Weibull (ajustat per fage) vs KM")
points(days0, survival, pch = 21, col = "blue")
points(days1, survival, pch = 16, col = "red")
legend("topright", c("KM Home", "KM Dona", "Weib. Home", "Weib. Dona"),
       lty = c(1, 3, NA, NA), pch = c(NA, NA, 21, 16),
       col = c("blue", "red", "blue", "red"), cex = 0.8)
```

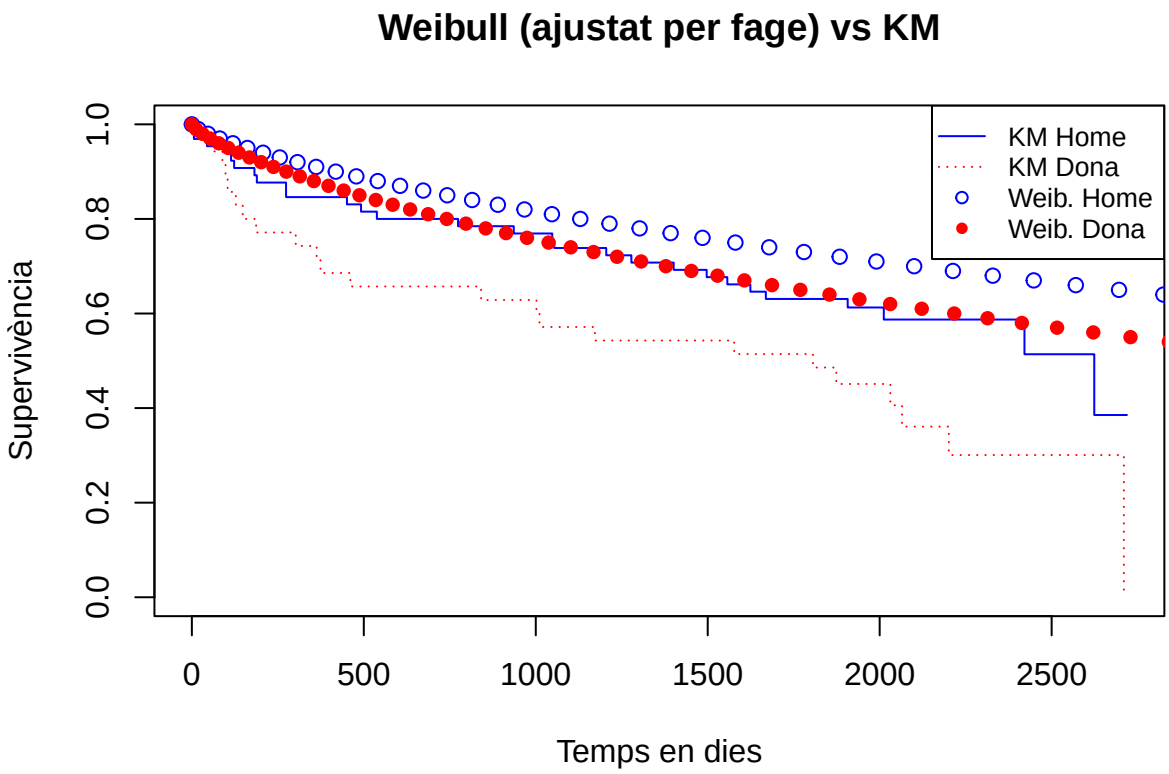

El gràfic mostra que **el model de Weibull ajustat per fage no s'ajusta bé a les dades**. Les corbes de Weibull per a homes i dones són pràcticament idèntiques i superposades, mentre que les corbes de Kaplan-Meier mostren una diferència clara entre els dos grups. Això indica que el model, un cop controlada l'edat, no és capaç de capturar la diferència de supervivència entre gèneres, cosa coherent amb el FA i HR no significatius obtinguts anteriorment. A més, el model sobrestima significativament la supervivència de les dones, ja que la corba de Weibull se situa molt per sobre de la KM corresponent al llarg de gairebé tot el període de seguiment. Aquest resultat indica que cal buscar alternatives per tal d'obtenir un model que expliqui millor la realitat de les dades.

Variable IBM

```
# Gràfic log-log per validar Weibull estratificant per fbmi
km.fbmi <- survfit(surv.whas ~ fbmi, data = data)
plot(km.fbmi, fun = "cloglog",
     xlab = "Log(Temps en dies)", ylab = "log-log Supervivència",
     lty = c(1, 3))
legend("topleft", c("Baix", "Alt"), lty = c(1, 3))
title("Corbes log-log per fbmi")
```

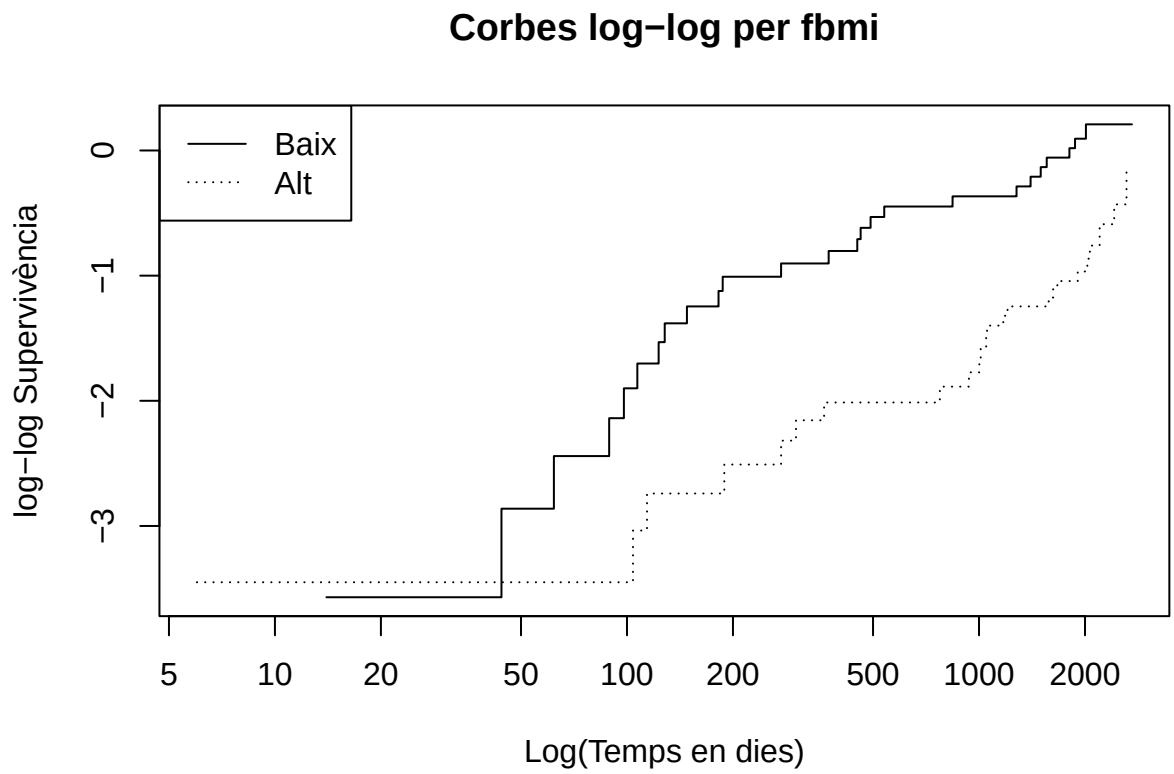

Les corbes log-log per fbmi mostren un **comportament més proper a la linealitat que en el cas de fage**, i s'aprecia un **cert paral·lelisme** entre els dos grups al llarg del rang temporal, especialment a la part central. Això recolza de manera més clara el compliment de les hipòtesis del model de Weibull i de riscos proporcionals. S'observa que el grup amb BMI baix presenta una taxa de risc superior al grup amb BMI alt, indicant una **millor supervivència associada a un índex de massa corporal més elevat**.

El model amb gènere i bmi factor:

```r
m.weib.bmi <- survreg(surv.whas ~ gender + fbmi, dist = "weibull", data = data)
summary(m.weib.bmi)
```

```
##
## Call:
## survreg(formula = surv.whas ~ gender + fbmi, data = data, dist = "weibull")
##               Value Std. Error     z      p
## (Intercept)  7.670      0.312 24.60 <2e-16
## gender      -0.752      0.373 -2.01 0.0439
## fbmi         1.207      0.381  3.17 0.0015
## Log(scale)   0.262      0.126  2.08 0.0374
##
## Scale= 1.3
##
## Weibull distribution
## Loglik(model)= -447.9   Loglik(intercept only)= -455.3
##  Chisq= 14.61 on 2 degrees of freedom, p= 0.00067
## Number of Newton-Raphson Iterations: 5
## n= 100
```

```r
m.weib.bmi$scale
```

```
## [1] 1.299064
```

```r
1 / m.weib.bmi$scale
```

```
## [1] 0.7697847
```

El model de Weibull ajustat per IMC mostra que **ambdues variables són significatives**. El coeficient de **fbmi és significatiu** ($p = 0.0015$), indicant que els **pacients amb IMC alt presenten un temps de supervivència significativament superior**. A diferència del model ajustat per edat, el coeficient de **gender continua sent significatiu** ($p = 0.044$) un cop controlat l'IMC, cosa que suggereix que **l'IMC no actua com a confusor de la relació entre gènere i supervivència**, sinó com una variable independent addicional.

El paràmetre d'escala ($1/p = 0.77$, $p < 1$) indicaria una **taxa de risc decreixent**, tot i que el test sobre Log(scale) és significatiu ($p = 0.037$), confirmant que $p \neq 1$ i que el model de Weibull és preferible a l'exponencial. El test global del model és significatiu ($p < 0.001$).

```r
# LRT vs model amb només gender
(chisq.bmi2 <- -2 * (m.weib$loglik[2] - m.weib.bmi$loglik[2]))
```

```
## [1] 10.45522
```

```r
1 - pchisq(chisq.bmi2, df = 1)
```

```
## [1] 0.001223036
```

El test de versemblança entre el model amb només gender i el model que incorpora fbmi és significatiu (estadístic = 10.46, p-valor = 0.001), indicant que afegir l'IMC millora significativament l'ajust del model. Per tant, fbmi és una variable rellevant que contribueix a explicar el temps de supervivència més enllà de l'efecte del gènere.

```r
# comparació d'AIC incloent o no fbmi
extractAIC(m.weib)
```

```
## [1]   3.000 912.342
```

```r
extractAIC(m.weib.bmi)
```

```
## [1]   4.0000 903.8868
```

L'AIC del model amb gender i fbmi (903.89) és inferior al del model amb només gender (912.34), confirmant que **la inclusió de l'IMC millora l'ajust del model** penalitzant per complexitat. Aquest resultat és coherent amb el test de versemblança i reforça la decisió d'incloure fbmi com a covariable.

```r
# FA i HR (gender ajustat per fbmi)
exp(m.weib.bmi$coef[2])
```

```
##   gender
## 0.471208
```

```r
c(exp(m.weib.bmi$coef[2] - 1.96 * sqrt(m.weib.bmi$var[2, 2])),
  exp(m.weib.bmi$coef[2] + 1.96 * sqrt(m.weib.bmi$var[2, 2])))
```

```
##    gender    gender
## 0.2266419 0.9796819
```

```r
exp(-m.weib.bmi$coef[2] / m.weib.bmi$scale)
```

```
##   gender
## 1.784662
```

El **factor d'acceleració (FA) de les dones respecte dels homes**, ajustat per IMC, és de 0.47 (IC 95%: 0.23 – 0.98). L'interval de confiança **no conté l'1**, confirmant que **l'efecte del gènere és estadísticament significatiu un cop controlat l'IMC**. Això significa que el temps de supervivència de les dones és 0.47 vegades el dels homes, és a dir, **les dones presenten una supervivència inferior**.

En termes de **hazard ratio (HR)**, les **dones** presenten un **risc instantani de mort 1.78 vegades superior al dels homes ajustat per IMC**, i aquest efecte sí que és significatiu.

```
pattern0 <- data.frame(gender = factor("Home", levels = c("Home", "Dona")), fbmi = 0)
pattern1 <- data.frame(gender = factor("Dona", levels = c("Home", "Dona")), fbmi = 0)

pct2     <- 0:100 / 100
survival <- 1 - pct2
days0 <- predict(m.weib.bmi, newdata = pattern0, type = "quantile", p = pct2)
days1 <- predict(m.weib.bmi, newdata = pattern1, type = "quantile", p = pct2)

plot(km.gender, xlab = "Temps en dies", ylab = "Supervivència",
     lty = c(1, 3), col = c("blue", "red"),
     main = "Weibull (ajustat per fbmi) vs KM")
points(days0, survival, pch = 21, col = "blue")
points(days1, survival, pch = 16, col = "red")
legend("topright", c("KM Home", "KM Dona", "Weib. Home", "Weib. Dona"),
       lty = c(1, 3, NA, NA), pch = c(NA, NA, 21, 16),
       col = c("blue", "red", "blue", "red"), cex = 0.8)
```

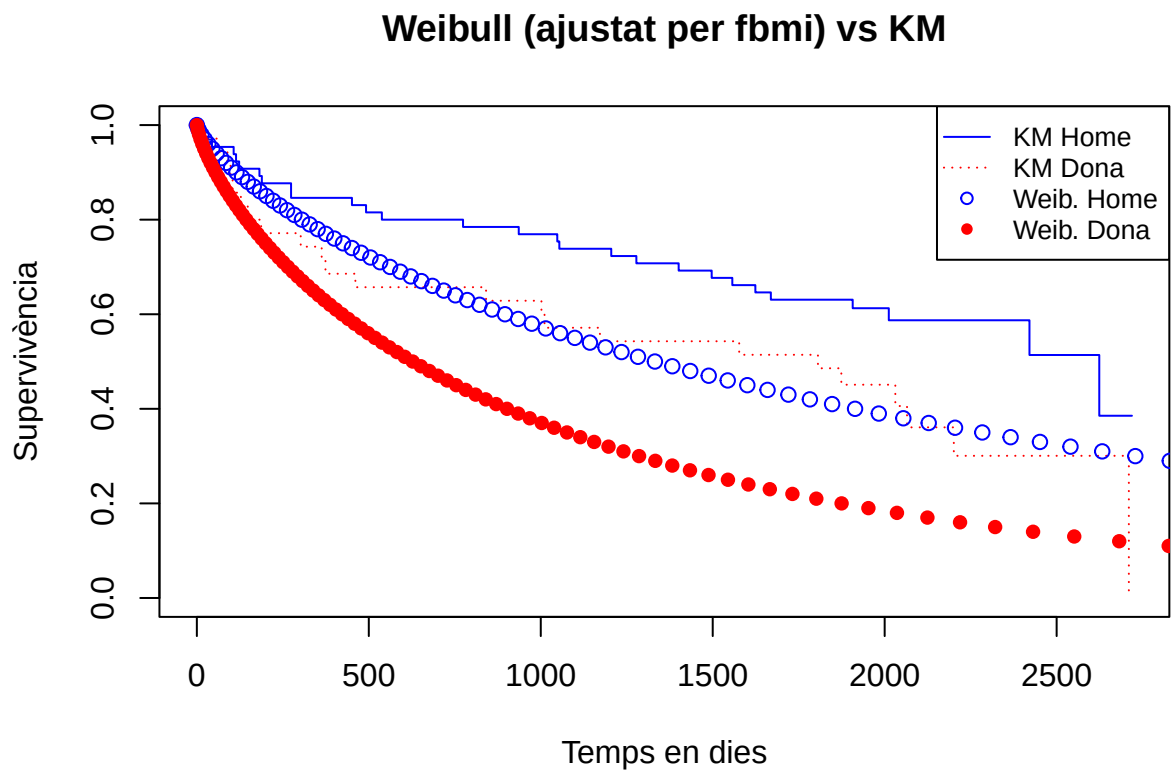

El gràfic mostra que **el model de Weibull ajustat per fbmi captura correctament la separació entre homes i dones**, cosa que el model ajustat per fage no aconseguia. No obstant, **l'ajust no és satisfactori**: el model **infraestima significativament la supervivència de ambdós grups** al llarg de

pràcticament tot el període de seguiment, amb les corbes de Weibull molt per sota de les KM corresponents.

Això indica que afegir fbmi i gènere no és suficient per modelar la realitat de les dades. Cal buscar altres combinacions de variables o afegir interaccions.

Conjuntament

Construïm el model que inclou totes 3 variables: **gènere**, **edat** i **ibm**.

Tindrem en compte **l'efecte d'interacció** entre les variables, escollint el model amb millor AIC.

```r
# Selecció del millor model per AIC
step(survreg(surv.whas ~ gender + fage + fbmi +
             gender:fage + gender:fbmi + fage:fbmi,
             dist = "weibull", data = data))
```

```
## Start:  AIC=896.77
## surv.whas ~ gender + fage + fbmi + gender:fage + gender:fbmi +
##     fage:fbmi
##
##               Df    AIC
## - gender:fbmi  1 895.58
## - fage:fbmi    1 895.78
## <none>           896.77
## - gender:fage  1 902.94
##
## Step:  AIC=895.58
## surv.whas ~ gender + fage + fbmi + gender:fage + fage:fbmi
##
##               Df    AIC
## - fage:fbmi    1 894.23
## <none>           895.58
## - gender:fage  1 900.98
##
## Step:  AIC=894.23
## surv.whas ~ gender + fage + fbmi + gender:fage
##
##               Df    AIC
## <none>           894.23
## - gender:fage  1 898.99
## - fbmi         1 903.09
```

```
## Call:
## survreg(formula = surv.whas ~ gender + fage + fbmi + gender:fage,
##     data = data, dist = "weibull")
##
## Coefficients:
## (Intercept)      gender        fage        fbmi gender:fage
##    8.510629   -1.888191   -1.768545    1.262805    2.127240
##
## Scale= 1.247418
##
## Loglik(model)= -441.1   Loglik(intercept only)= -455.3
##  Chisq= 28.27 on 4 degrees of freedom, p= 1.1e-05
## n= 100
```

El model seleccionat per step() és **gender + fage + fbmi + gender:fage.**

Això vol dir que el **millor balanç** entre **ajust** a les dades i **complexitat** del model inclou una **interacció significativa** entre **gènere i edat**. En canvi, l'efecte de l'IBM no varia independentment del gènere o l'edat.

Construïm el model:

```
# Model final seleccionat per step
m.weib.full <- survreg(surv.whas ~ gender + fage + fbmi + gender:fage,
                       dist = "weibull", data = data)
summary(m.weib.full)
```

```
##
## Call:
## survreg(formula = surv.whas ~ gender + fage + fbmi + gender:fage,
##     data = data, dist = "weibull")
##              Value Std. Error     z       p
## (Intercept)  8.511      0.476 17.88 < 2e-16
## gender      -1.888      0.679 -2.78 0.00543
## fage        -1.769      0.535 -3.30 0.00095
## fbmi         1.263      0.394  3.20 0.00136
## gender:fage  2.127      0.820  2.59 0.00951
## Log(scale)   0.221      0.124  1.79 0.07395
##
## Scale= 1.25
##
## Weibull distribution
## Loglik(model)= -441.1   Loglik(intercept only)= -455.3
##  Chisq= 28.27 on 4 degrees of freedom, p= 1.1e-05
## Number of Newton-Raphson Iterations: 5
## n= 100
```

```
m.weib.full$scale
```

```
## [1] 1.247418
```

```
1 / m.weib.full$scale
```

```
## [1] 0.8016559
```

El model final seleccionat inclou **gender, fage, fbmi i la interacció gender:fage**, i **tots els coeficients són significatius**. La presència de la interacció indica que **l'efecte del gènere sobre la supervivència depèn de l'edat del pacient**, de manera que **no es pot interpretar l'efecte de gender de forma aïllada sense tenir en compte fage**.

El coeficient de **gender (-1.888)** representa l'efecte del gènere **per als pacients menors de 70 anys (fage = 0)**, mentre que el terme **d'interacció gender:fage (2.127)** indica que aquest **efecte s'atenua** substancialment — i fins i tot **s'inverteix** — en els **pacients majors de 70 anys**. El paràmetre fbmi continua sent significatiu ($p = 0.001$), confirmant que **un IMC alt s'associa a una major supervivència** independentment del gènere i l'edat. El test global del model és altament significatiu ($p < 0.001$) i l'escala ($1/p = 0.80$) indica una taxa de risc lleugerament decreixent.

```
# LRT vs model amb només gender
(chisq.full2 <- -2 * (m.weib$loglik[2] - m.weib.full$loglik[2]))
```

```
## [1] 24.11399
```

```
1 - pchisq(chisq.full2, df = 3)
```

```
## [1] 2.364791e-05
```

El **test de versemblança** entre el model amb **només gender** i el **model final** és altament significatiu

(estadístic = 24.11, p-valor < 0.001), confirmant que la inclusió conjunta de fage, fbmi i la interacció gender:fage millora de manera molt substancial l'ajust del model respecte a considerar únicament el gènere.

```
extractAIC(m.weib)
```

```
## [1]   3.000 912.342
```

```
extractAIC(m.weib.full)
```

```
## [1]   6.000 894.228
```

L'AIC del **model final** (894.23) és **considerablement inferior** al del model amb **només gender** (912.34), amb una diferència de gairebé 18 punts. Això confirma que la inclusió de fage, fbmi i la interacció gender:fage millora substancialment l'ajust del model, justificant la major complexitat dels 3 paràmetres addicionals.

```
# FA i HR per gender (homes, fage=0)
exp(m.weib.full$coef["gender"])
```

```
##    gender
## 0.1513453
```

```
c(exp(m.weib.full$coef["gender"] - 1.96 * sqrt(m.weib.full$var["gender", "gender"])),
  exp(m.weib.full$coef["gender"] + 1.96 * sqrt(m.weib.full$var["gender", "gender"])))
```

```
##     gender     gender
## 0.03998923 0.57278917
```

```
exp(-m.weib.full$coef["gender"] / m.weib.full$scale)
```

```
##   gender
## 4.543419
```

Per als **pacients menors de 70 anys** (fage = 0), el **factor d'acceleració de les dones respecte dels homes** és de **0.15** (IC 95%: 0.04 – 0.57), és a dir, el **temps de supervivència de les dones joves és només 0.15 vegades el dels homes joves**. L'interval de confiança no conté l'1, confirmant que aquest efecte és estadísticament significatiu.

En termes de **HR**, les **dones menors de 70 anys** presenten un **risc instantani de mort 4.54 vegades superior al dels homes** del mateix grup d'edat. Això indica que, entre els pacients joves, el gènere femení és un factor de risc important per a la supervivència després d'un infart agut de miocardi.

```
# FA estratificat per gènere
# Tractament per homes (gender=1, fage=0 vs gender=0, fage=0)
est.home <- m.weib.full$coef["gender"] + m.weib.full$coef["gender:fage"] * 0
exp(est.home)
```

```
##    gender
## 0.1513453
```

```
# Tractament per dones grans (gender=1, fage=1 vs gender=0, fage=1)
est.fage1 <- m.weib.full$coef["gender"] + m.weib.full$coef["gender:fage"] * 1
exp(est.fage1)
```

```
##  gender
## 1.27004
```

```
var.fage1 <- m.weib.full$var["gender", "gender"] +
             m.weib.full$var["gender:fage", "gender:fage"] +
             2 * m.weib.full$var["gender", "gender:fage"]
exp(c(est.fage1 - 1.96 * sqrt(var.fage1),
      est.fage1 + 1.96 * sqrt(var.fage1)))
```

```
##    gender    gender
## 0.5485342 2.9405677
```

Els resultats confirmen **l'efecte diferencial del gènere segons l'edat**. Per als pacients menors de 70 anys (fage = 0), el FA és de 0.15, indicant que les dones joves presenten una supervivència molt inferior a la dels homes joves, tal com s'ha comentat anteriorment.

En canvi, per als **pacients majors de 70 anys** (fage = 1), el **FA de les dones respecte dels homes és de 1.27** (IC 95%: 0.55 – 2.94). Com que **l'interval de confiança conté l'1**, no podem considerar que hi hagi diferències significatives en la supervivència entre homes i dones d'edat avançada. Això indica que **el tractament diferencial del gènere sobre la supervivència només és rellevant en el grup de pacients més joves, mentre que en els pacients majors de 70 anys l'efecte del gènere desapareix.**

```r
pattern0 <- data.frame(gender = factor("Home", levels = c("Home", "Dona")), fage = 0, fbmi = 0)
pattern1 <- data.frame(gender = factor("Dona", levels = c("Home", "Dona")), fage = 0, fbmi = 0)

pct2     <- 0:100 / 100
survival <- 1 - pct2
days0 <- predict(m.weib.full, newdata = pattern0, type = "quantile", p = pct2)
days1 <- predict(m.weib.full, newdata = pattern1, type = "quantile", p = pct2)

plot(km.gender, xlab = "Temps en dies", ylab = "Supervivència",
     lty = c(1, 3), col = c("blue", "red"),
     main = "Weibull (model final) vs KM")
points(days0, survival, pch = 21, col = "blue")
points(days1, survival, pch = 16, col = "red")
legend("topright", c("KM Home", "KM Dona", "Weib. Home", "Weib. Dona"),
       lty = c(1, 3, NA, NA), pch = c(NA, NA, 21, 16),
       col = c("blue", "red", "blue", "red"), cex = 0.8)
```

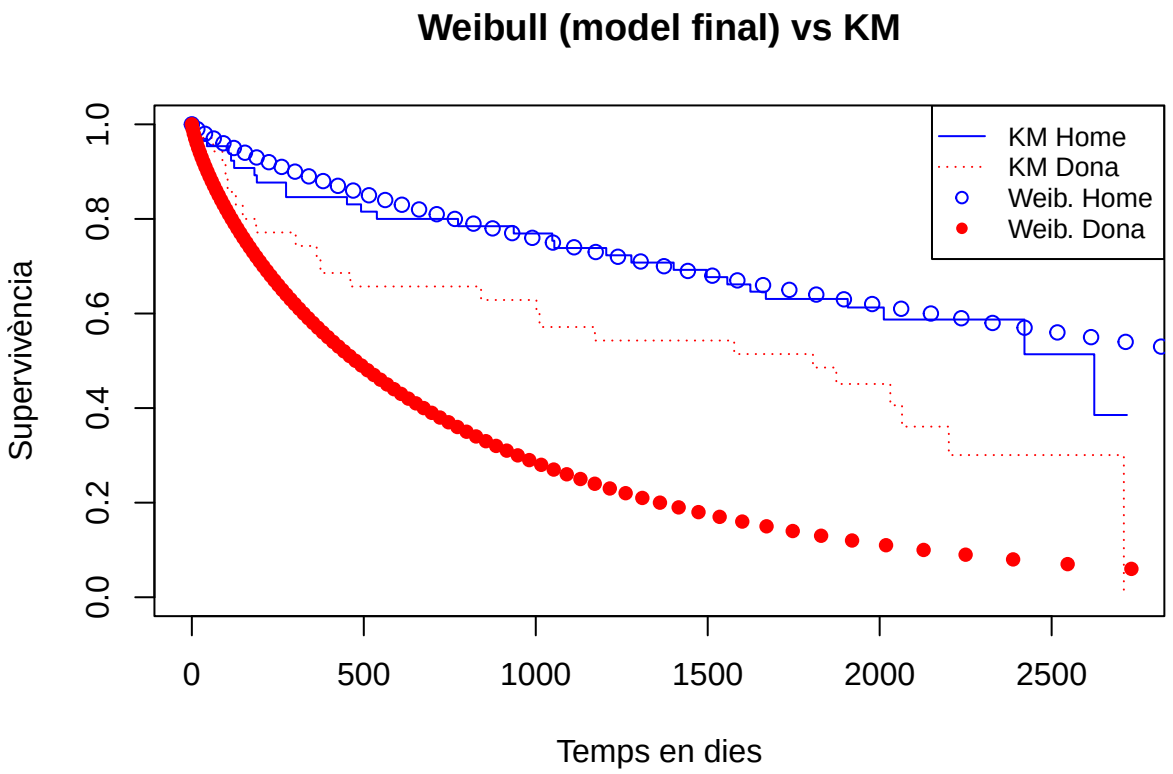

El gràfic mostra que el **model final de Weibull** només s'ajusta adequadament per als homes, seguint de prop la corba de Kaplan-Meier corresponent al llarg de tot el període de seguiment. Per a les dones, en canvi, el model infraestima considerablement la supervivència, amb la corba de Weibull molt per sota de la KM al llarg de pràcticament tot el seguiment. Aquesta discrepància és conseqüència de la interacció gender:fage: els patrons de predicció estan fixats a fage = 0, de manera que el model reflecteix el comportament de les dones joves, que presenten una supervivència molt inferior. Per obtenir una representació més fidel caldria graficar les corbes per a cada combinació de gender i fage per separat.

Observem els gràfics per separat:

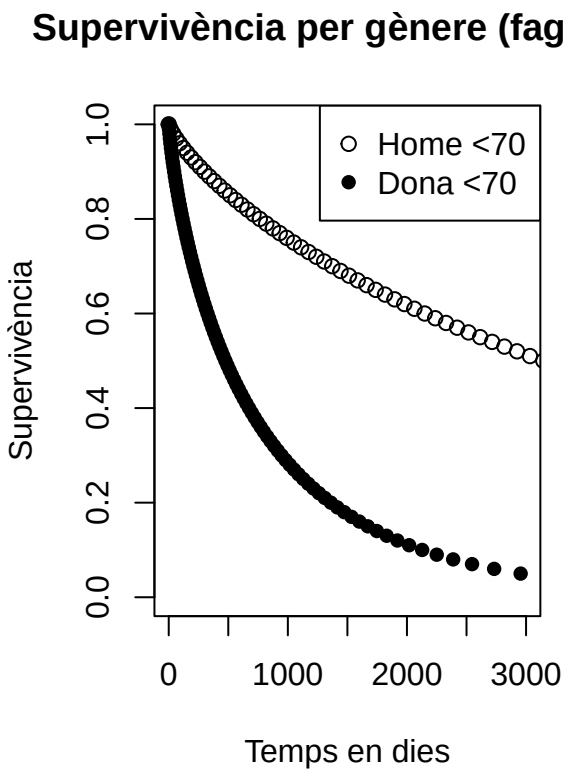

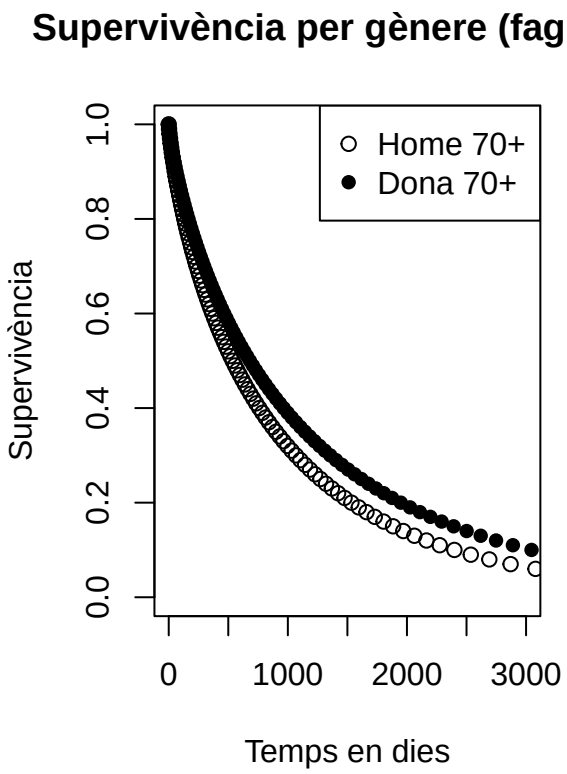

Els dos gràfics mostren les **prediccions del model final** de Weibull per a les **quatre combinacions de gènere i edat**, **fixant fbmi = 0**. En el gràfic de l'esquerra (fage = 0, menors de 70 anys), s'aprecia una **diferència molt pronunciada entre homes i dones**: els **homes** presenten una **supervivència notablement superior**, amb una corba que decau molt més lentament. Això és coherent amb el **FA de 0.15** obtingut anteriorment, confirmant que entre els **pacients joves** el **gènere femení** és un **factor de risc** molt rellevant.

En el gràfic de la dreta (fage = 1, majors de 70 anys), **les dues corbes són pràcticament superposades**, indicant que **la diferència de supervivència entre homes i dones desapareix completament en el grup de major edat**. Això és coherent amb el **FA de 1.27 (IC 95%: 0.55 - 2.94)** obtingut anteriorment, que **no era estadísticament significatiu**. Per tant, **la interacció gender:fage captura de manera precisa aquest comportament diferencial: el gènere només és un factor determinant de la supervivència en els pacients més joves.**

Model escollit

```
taula <- data.frame(
  Model     = c("Només gender", "gender + fage", "gender + fbmi",
                "gender + fage + fbmi", "gender + fage + fbmi + gender:fage"),
  AIC       = round(c(extractAIC(m.weib)[2],
                      extractAIC(m.weib.age)[2],
                      extractAIC(m.weib.bmi)[2],
                      extractAIC(survreg(surv.whas ~ gender + fage + fbmi,
                                         dist = "weibull", data = data))[2],
                      extractAIC(m.weib.full)[2]), 2),
  FA_gender = round(c(exp(m.weib$coef[2]),
                      exp(m.weib.age$coef[2]),
```

```
                        exp(m.weib.bmi$coef[2]),
                        exp(survreg(surv.whas ~ gender + fage + fbmi,
                                    dist = "weibull", data = data)$coef[2]),
                        exp(m.weib.full$coef["gender"])), 3),
  HR_gender = round(c(exp(-m.weib$coef[2]  / m.weib$scale),
                        exp(-m.weib.age$coef[2]  / m.weib.age$scale),
                        exp(-m.weib.bmi$coef[2]  / m.weib.bmi$scale),
                        exp(-survreg(surv.whas ~ gender + fage + fbmi,
                                     dist = "weibull", data = data)$coef[2] /
                            survreg(surv.whas ~ gender + fage + fbmi,
                                    dist = "weibull", data = data)$scale),
                        exp(-m.weib.full$coef["gender"] / m.weib.full$scale)), 3)
)
kable(taula, caption = "Comparació de models Weibull segons covariables incloses")
```

Table 4: Comparació de models Weibull segons covariables incloses

Model	AIC	FA_gender	HR_gender
Només gender	912.34	0.454	1.792
gender + fage	904.58	0.656	1.375
gender + fbmi	903.89	0.471	1.785
gender + fage + fbmi	898.99	0.698	1.325
gender + fage + fbmi + gender:fage	894.23	0.151	4.543

La taula resum mostra com **l'AIC millora progressivament a mesura que s'incorporen covariables al model**. Els models amb fage o fbmi individualment ja suposen una millora respecte al model amb només gender, i el model complet sense interacció (AIC = 898.99) millora encara més. No obstant, el salt més important es produeix en el **model final** (AIC = 894.23), que **incorpora la interacció gender:fage**.

Aquest canvi brusc en el **FA**, que passa de valors al voltant de **0.47–0.70** en els models anteriors a **0.15** en el model final, no indica que l'efecte del gènere sigui més extrem, sinó que reflecteix que **l'efecte del gènere depèn de l'edat**. En els models sense interacció, el coeficient de gender representa un efecte mitjà per a tots els pacients independentment de l'edat, amaguant el fet que l'efecte és molt diferent entre els menors i els majors de 70 anys. Un cop s'introdueix la interacció, el coeficient de gender passa a representar exclusivament l'efecte en els pacients menors de 70 anys, que és on la diferència entre homes i dones és realment pronunciada i significativa. Per tant, **la interacció gender:fage era clau per entendre correctament la relació entre gènere i supervivència en aquesta població.**

Això es pot observar al gràfic ja mostrat anteriorment que il · lustra perfectament **l'efecte interacció entre gènere i edat**:

```
par(mfrow = c(1, 2))

# Home <70 vs Dona <70
pattern0 <- data.frame(gender = factor("Home", levels = c("Home", "Dona")), fage = 0, fbmi = 0)
pattern1 <- data.frame(gender = factor("Dona", levels = c("Home", "Dona")), fage = 0, fbmi = 0)

days0 <- predict(m.weib.full, newdata = pattern0, type = "quantile", p = pct2)
days1 <- predict(m.weib.full, newdata = pattern1, type = "quantile", p = pct2)

plot(days0, survival, xlab = "Temps en dies", ylab = "Supervivència",
     main = "Supervivència per gènere (fage = 0)", xlim = c(0, 3000))
points(days1, survival, pch = 16)
legend("topright", c("Home <70", "Dona <70"), pch = c(21, 16))
```

```r
# Home 70+ vs Dona 70+
pattern0 <- data.frame(gender = factor("Home", levels = c("Home", "Dona")), fage = 1, fbmi = 0)
pattern1 <- data.frame(gender = factor("Dona", levels = c("Home", "Dona")), fage = 1, fbmi = 0)

days0 <- predict(m.weib.full, newdata = pattern0, type = "quantile", p = pct2)
days1 <- predict(m.weib.full, newdata = pattern1, type = "quantile", p = pct2)

plot(days0, survival, xlab = "Temps en dies", ylab = "Supervivència",
     main = "Supervivència per gènere (fage = 1)", xlim = c(0, 3000))
points(days1, survival, pch = 16)
legend("topright", c("Home 70+", "Dona 70+"), pch = c(21, 16))
```

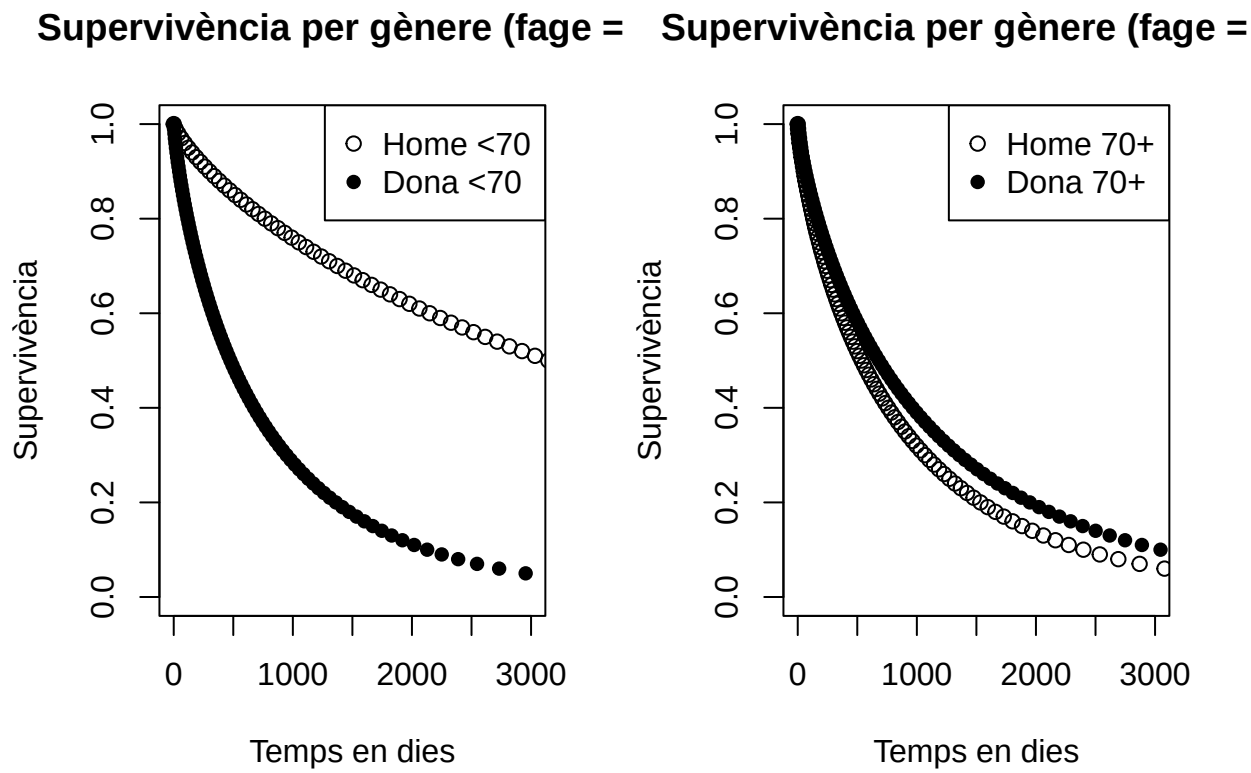


```r
par(mfrow = c(1, 1))
```

Factors d'acceleració del millor model

```r
# FA individuals i IC 95%

# gender (fage = 0)
exp(m.weib.full$coef["gender"])
```

```
##    gender
## 0.1513453
```

```r
c(exp(m.weib.full$coef["gender"] - 1.96 * sqrt(m.weib.full$var["gender", "gender"])),
  exp(m.weib.full$coef["gender"] + 1.96 * sqrt(m.weib.full$var["gender", "gender"])))
```

```
##     gender     gender
## 0.03998923 0.57278917
```

```r
# fage
exp(m.weib.full$coef["fage"])
```

```
##     fage
## 0.170581
```

```r
c(exp(m.weib.full$coef["fage"] - 1.96 * sqrt(m.weib.full$var["fage", "fage"])),
  exp(m.weib.full$coef["fage"] + 1.96 * sqrt(m.weib.full$var["fage", "fage"])))
```

```
##       fage       fage
## 0.05973796 0.48709163
```

```r
# fbmi
exp(m.weib.full$coef["fbmi"])
```

```
##     fbmi
## 3.535326
```

```r
c(exp(m.weib.full$coef["fbmi"] - 1.96 * sqrt(m.weib.full$var["fbmi", "fbmi"])),
  exp(m.weib.full$coef["fbmi"] + 1.96 * sqrt(m.weib.full$var["fbmi", "fbmi"])))
```

```
##     fbmi     fbmi
## 1.632282 7.657090
```

Els **factors d'acceleració individuals** mostren l'efecte de cada variable sobre el temps de supervivència mantenint la resta constant:

- **Gender (per a pacients menors de 70 anys, fage = 0)**: el FA és de 0.15 (IC 95%: 0.04 – 0.57), indicant que les dones joves presenten un temps de supervivència significativament inferior al dels homes joves. L'interval no conté l'1, confirmant la significació estadística.
- **Fage**: el FA és de 0.17 (IC 95%: 0.06 – 0.49), indicant que els pacients majors de 70 anys presenten un temps de supervivència que és només 0.17 vegades el dels pacients menors de 70 anys, és a dir, una supervivència molt inferior. L'efecte és estadísticament significatiu.
- **Fbmi**: el FA és de 3.54 (IC 95%: 1.63 – 7.66), indicant que els pacients amb IMC alt presenten un temps de supervivència 3.54 vegades superior al dels pacients amb IMC baix. És la variable amb l'efecte protector més pronunciat i estadísticament significatiu del model.

```r
# FA conjunts i IC 95%

# Dona vs Home, fage = 0 (ja calculat, FA = exp(alpha_gender))
est.dona.jove <- m.weib.full$coef["gender"]
exp(est.dona.jove)
```

```
##    gender
## 0.1513453
```

```r
var.dona.jove <- m.weib.full$var["gender", "gender"]
exp(c(est.dona.jove - 1.96 * sqrt(var.dona.jove),
      est.dona.jove + 1.96 * sqrt(var.dona.jove)))
```

```
##     gender     gender
## 0.03998923 0.57278917
```

```r
# Dona vs Home, fage = 1 (FA = exp(alpha_gender + alpha_gender:fage))
est.dona.gran <- m.weib.full$coef["gender"] + m.weib.full$coef["gender:fage"]
exp(est.dona.gran)
```

```
##  gender
## 1.27004
```

```r
var.dona.gran <- m.weib.full$var["gender", "gender"] +
                 m.weib.full$var["gender:fage", "gender:fage"] +
                 2 * m.weib.full$var["gender", "gender:fage"]
exp(c(est.dona.gran - 1.96 * sqrt(var.dona.gran),
      est.dona.gran + 1.96 * sqrt(var.dona.gran)))
```

```
##    gender    gender
## 0.5485342 2.9405677
```

```r
# fage = 1 i fbmi = 1 vs fage = 0 i fbmi = 0 (FA = exp(alpha_fage + alpha_fbmi))
est.conjunt <- m.weib.full$coef["fage"] + m.weib.full$coef["fbmi"]
exp(est.conjunt)
```

```
##      fage
## 0.6030592
```

```r
var.conjunt <- m.weib.full$var["fage", "fage"] +
               m.weib.full$var["fbmi", "fbmi"] +
               2 * m.weib.full$var["fage", "fbmi"]
exp(c(est.conjunt - 1.96 * sqrt(var.conjunt),
      est.conjunt + 1.96 * sqrt(var.conjunt)))
```

```
##      fage      fage
## 0.1746027 2.0829031
```

Els **factors d'acceleració conjunts** permeten comparar combinacions de categories entre si:

- **Dona vs Home, menors de 70 anys (fage = 0)**: FA = 0.15 (IC 95%: 0.04 – 0.57). Les dones joves presenten una supervivència significativament inferior als homes joves, amb un efecte estadísticament significatiu ja que l'interval no conté l'1.
- **Dona vs Home, majors de 70 anys (fage = 1)**: FA = 1.27 (IC 95%: 0.55 – 2.94). Entre els pacients majors de 70 anys, les dones presenten un temps de supervivència lleugerament superior al dels homes, però l'interval conté l'1 i per tant l'efecte no és estadísticament significatiu. Això confirma que la diferència de supervivència entre gèneres desapareix en el grup de major edat.
- **Pacients majors de 70 anys amb IMC alt vs menors de 70 anys amb IMC baix (fage = 1, fbmi = 1 vs fage = 0, fbmi = 0)**: FA = 0.60 (IC 95%: 0.17 – 2.08). L'efecte combinat de l'edat avançada i l'IMC alt resulta en un FA proper a 1 i amb un interval que conté l'1, indicant que els efectes contraris de les dues variables — l'edat redueix la supervivència mentre que l'IMC alt l'augmenta — es compensen parcialment, sense que la diferència global sigui estadísticament significativa.

HR

Conclusion