

Análisis de Supervivencia en Pacientes que han Sufrido un Ictus

Trabajo de Evaluación Continuada — Segunda Parte

Curso 2024-25

Contents

1	Introducción y contexto del estudio	2
2	Descripción de las variables	2
3	Objetivos del análisis	3
4	Planteamiento metodológico	4
4.1	El modelo de Cox	4
4.2	Modelo estratificado	5
4.3	Modelo ampliado	5
4.4	Hipótesis de proporcionalidad y modelo de Cox extendido	5
4.5	Formulación del modelo de Cox extendido	7
5	Exploración inicial de los datos	7
5.1	Carga de librerías y datos	7
5.2	Resumen descriptivo	7
5.3	Curvas de Kaplan-Meier	9
6	Modelos de regresión de Cox	10
6.1	Definición del objeto de supervivencia y modelos básicos	10
7	Evaluación del supuesto de riesgos proporcionales	13
7.1	Método gráfico: curvas log-log	13
7.2	Test de Schoenfeld	14
7.3	Residuos de Schoenfeld	14

1 Introducción y contexto del estudio

Antes de aplicar a los datos un modelo de Cox, tanto en su versión estratificada como ampliada, es necesario contextualizar el problema y explicar los supuestos que deben cumplirse para poder interpretar correctamente los resultados obtenidos. En particular, estos modelos requieren que las variables consideradas satisfagan la hipótesis de riesgos proporcionales.

El ictus constituye una de las principales causas de muerte y discapacidad en el mundo. Esta enfermedad se produce cuando el flujo sanguíneo hacia una parte del cerebro se interrumpe de manera repentina, provocando daños cerebrales que pueden llegar a ser fatales. Según la Organización Mundial de la Salud, el ictus causa aproximadamente 5,5 millones de muertes al año a nivel mundial, siendo la segunda causa de muerte más frecuente después de las enfermedades coronarias.

En este contexto, el análisis de supervivencia resulta especialmente útil para estudiar el tiempo hasta la aparición de un determinado evento, permitiendo evaluar cómo diferentes factores clínicos y demográficos influyen en el riesgo asociado a la supervivencia de los pacientes que han sufrido un

En este trabajo se analizan los datos de un estudio de seguimiento prospectivo llevado a cabo en una red de hospitales públicos españoles. El estudio tiene como objetivo evaluar la **supervivencia de pacientes tras haber sufrido un ictus**, así como identificar qué factores influyen en el riesgo de fallecimiento durante los dos años posteriores al episodio.

Un aspecto central del estudio es la comparación entre el **tratamiento estándar** actualmente empleado en la práctica clínica y un **nuevo tratamiento** que se encuentra aún en fase de evaluación pero no obstante, ha mostrado resultados prometedores en estudios previos. Junto con el tipo de tratamiento, se recogen también características básicas del paciente en el momento del ingreso que podrían condicionar su evolución.

El evento de interés es el **fallecimiento del paciente** durante el período de seguimiento. Los pacientes que siguen vivos al finalizar los dos años de seguimiento, concluyendo a un estudio aproximado de unos 730 días, al igual que aquellos que abandonan el estudio antes de su conclusión se consideran **observaciones censuradas por la derecha**, al no conocer con exactitud el tiempo de supervivencia es inferior o igual al tiempo exacto de supervivencia.

2 Descripción de las variables

La muestra está formada por **1.400 pacientes** ingresados tras sufrir un ictus. Para cada uno de ellos se dispone de las siguientes variables:

Variable	Descripción	Tipo
Survvt	Tiempo de supervivencia desde el ictus hasta el fallecimiento o hasta la censura, medido en días	Cuantitativa continua
Status	Variable de censura: 1 si el paciente fallece durante el seguimiento; 0 si no se produce el evento	Binaria
x1	Tipo de tratamiento: 1 = tratamiento estándar; 0 = nuevo tratamiento en estudio	Binaria
x2	Edad del paciente en el momento del ictus, en años	Cuantitativa continua
x3	Presión arterial sistólica registrada al ingreso hospitalario, en mmHg	Cuantitativa continua
x4	Sexo del paciente: 1 = mujer; 0 = hombre	Binaria
x5	Índice de masa corporal (IMC) del paciente al ingreso, en kg/m ²	Cuantitativa continua

A continuación, se describe el papel esperado de cada variable en el análisis que se realizará posteriormente, así como el tipo de variable al que pertenece cada una de ellas según la clasificación previamente definida.

- **x1 — Tratamiento:** Es la variable de interés principal del estudio. Se compara si los pacientes que reciben el nuevo tratamiento en evaluación presentan una supervivencia mayor que los que reciben el tratamiento estándar.
- **x2 — Edad:** A mayor edad, el organismo tiende a tener menor capacidad de recuperación y mayor vulnerabilidad ante las complicaciones, por lo que se espera que la edad esté asociada a un mayor riesgo de fallecimiento.
- **x3 — Presión arterial sistólica al ingreso:** Refleja el estado cardiovascular del paciente en el momento del episodio. Tanto valores muy bajos como muy elevados pueden indicar mayor gravedad y asociarse a un peor pronóstico.
- **x4 — Sexo:** Existen diferencias entre hombres y mujeres en la incidencia y evolución del ictus. Se incluye como posible factor de confusión o modificador del efecto del tratamiento.
- **x5 — IMC:** El índice de masa corporal es un indicador del estado nutricional general del paciente. Valores extremos pueden estar asociados a un peor pronóstico durante el seguimiento.

3 Objetivos del análisis

El análisis se estructura en torno a los siguientes objetivos:

1. Describir la supervivencia global de los pacientes mediante el estimador de Kaplan-Meier y comparar las curvas de supervivencia según el tipo de tratamiento recibido.
2. Ajustar un **modelo de Cox estándar** que permita estimar el efecto de cada covariable sobre el riesgo de fallecimiento, controlando simultáneamente por el resto de factores.
3. Verificar el **supuesto de proporcionalidad de riesgos** del modelo de Cox para cada covariable, mediante el test de Schoenfeld y el análisis gráfico correspondiente.

4. En caso de que alguna covariable no cumpla el supuesto de proporcionalidad, ajustar un **modelo de Cox estratificado** que permita que la función de riesgo basal varíe entre los grupos definidos por dicha variable.
 5. Considerar un **modelo de Cox ampliado** que incorpore covariables dependientes del tiempo, como alternativa o complemento al modelo estratificado.
 6. Interpretar todos los resultados en términos de *hazard ratios* (HR) e intervalos de confianza al 95%, en el contexto del estudio de supervivencia tras ictus.
-

4 Planteamiento metodológico

4.1 El modelo de Cox

El modelo de regresión de Cox (Cox, 1972) es el modelo semiparamétrico de referencia en el análisis de supervivencia. Permite estudiar el efecto de un conjunto de covariables sobre el riesgo instantáneo de que ocurra el evento de interés (en este caso, el fallecimiento), sin necesidad de asumir ninguna forma paramétrica concreta para dicho riesgo a lo largo del tiempo.

Para el individuo i , el modelo expresa la función de riesgo como:

$$h_i(t) = h_0(t) \cdot \exp(\beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{3i} + \beta_4 x_{4i} + \beta_5 x_{5i})$$

donde $h_0(t)$ es la función de riesgo basal, común a todos los individuos, y los coeficientes β_j miden el efecto de cada covariable. El exponencial de cada coeficiente, $\exp(\beta_j)$, se interpreta como el **hazard ratio (HR)**: cuántas veces es mayor el riesgo de un grupo respecto al de referencia, manteniendo fijas el resto de variables.

El modelo de Cox estándar asume que los riesgos de los distintos grupos son **proporcionales** a lo largo del tiempo, es decir, que el HR entre dos individuos cualesquiera es constante en el tiempo. Este supuesto debe verificarse.

El modelo de Cox se considera un modelo *semiparamétrico* debido a que combina una parte paramétrica y otra no paramétrica.

4.1.1 Parte paramétrica

La parte paramétrica del modelo viene dada por:

$$\exp\left(\sum_{j=1}^p \beta_j X_j\right),$$

es decir, por la exponencial del predictor lineal:

$$\eta = \sum_{j=1}^p \beta_j X_j.$$

En esta componente se estiman los parámetros de regresión

$$\hat{\beta} = (\hat{\beta}_1, \dots, \hat{\beta}_p)$$

mediante la maximización de la denominada *función de verosimilitud parcial*, la cual constituye uno de los elementos fundamentales del modelo de Cox.

4.1.2 Parte no paramétrica

La parte no paramétrica corresponde a la función de riesgo basal $h_0(t)$. Esta función no se especifica previamente y se considera arbitraria, por lo que debe estimarse posteriormente condicionada a los valores obtenidos para los parámetros de regresión.

Debido a esta combinación entre una componente paramétrica y otra no paramétrica, el modelo de Cox recibe el nombre de modelo *semiparamétrico*.

Una vez estimadas ambas componentes, el modelo completo queda expresado como:

$$\hat{h}(t | \mathbf{X}) = \hat{h}_0(t) \exp \left(\sum_{j=1}^p \hat{\beta}_j X_j \right).$$

Tal como se ha mencionado anteriormente, en el modelo de Cox la función de riesgo basal $h_0(t)$ no está especificada explícitamente y, por tanto, tampoco lo está la distribución del término de error.

En cambio, en los modelos paramétricos la forma funcional de la distribución sí se encuentra completamente especificada, salvo por un conjunto reducido de parámetros desconocidos que deben ser estimados a partir de los datos.

4.2 Modelo estratificado

Si una covariable viola el supuesto de proporcionalidad, una solución es **estratificar** el modelo por dicha variable. En este caso, se permite que cada estrato tenga su propia función de riesgo basal $h_{0g}(t)$, mientras que el efecto del resto de covariables sigue siendo común a todos los estratos:

$$h_{ig}(t) = h_{0g}(t) \cdot \exp \left(\sum_j \beta_j x_{ij} \right)$$

La variable de estratificación no genera un coeficiente propio (no se obtiene un HR para ella), pero su efecto sobre el riesgo basal queda controlado.

4.3 Modelo ampliado

4.4 Hipótesis de proporcionalidad y modelo de Cox extendido

Uno de los supuestos fundamentales del modelo de Cox es la hipótesis de riesgos proporcionales. Esta hipótesis establece que el efecto de las covariables sobre el riesgo permanece constante a lo largo del tiempo, es decir, que las razones de riesgo (*hazard ratios*) entre individuos son proporcionales durante todo el periodo de seguimiento.

Cuando esta condición no se cumple, el efecto de algunas variables puede variar temporalmente, lo que implica que el modelo de Cox clásico deja de ser completamente adecuado. Por ello, antes de interpretar los resultados obtenidos, es necesario verificar si la hipótesis de proporcionalidad se satisface para cada predictor incluido en el modelo.

Como ya se ha comentado anteriormente, la hipótesis de riesgos proporcionales puede evaluarse mediante tres metodologías principales:

1. Métodos gráficos, como las curvas log-log o la comparación entre valores “observados” y “esperados”.
2. Contrastes estadísticos específicos, como el test de Schoenfeld.
3. Inclusión de variables dependientes del tiempo mediante un modelo de Cox extendido.

El modelo de Cox ampliado permite incorporar covariables dependientes del tiempo, cuyo valor o efecto puede cambiar a lo largo del seguimiento. Una forma habitual de abordar la falta de proporcionalidad consiste en introducir un término de interacción entre la covariable problemática y una función temporal, por ejemplo $x_j \cdot \log(t)$:

$$h_i(t) = h_0(t) \cdot \exp(\beta_j x_{ji} + \gamma_j [x_{ji} \cdot \log(t)] + \dots)$$

En este caso, el parámetro γ_j mide cómo evoluciona el efecto de la covariable con el tiempo. Si dicho coeficiente resulta estadísticamente significativo, se concluye que el efecto de la variable no permanece constante y, por tanto, que se viola la hipótesis de riesgos proporcionales.

Cuando, tras evaluar esta hipótesis, se detecta que uno o varios predictores no cumplen la proporcionalidad, existen dos alternativas principales:

1. Aplicar un modelo de Cox estratificado, estratificando por las variables que incumplen la hipótesis y manteniendo el resto como covariables ordinarias.
2. Incorporar variables dependientes del tiempo mediante un modelo de Cox extendido.

En esta sección se desarrollará la segunda alternativa.

4.4.1 Tipos de variables dependientes del tiempo

Existen variables que dependen intrínsecamente del tiempo, ya que sus valores evolucionan según las propias características del individuo. Algunos ejemplos son:

- Nivel de exposición en el instante t , $E(t)$.
- Estado laboral en el instante t , $EMP(t)$.
- Estado de fumador en el instante t , $SMK(t)$.
- Nivel de obesidad en el instante t , $OBS(t)$.

Por otro lado, existen variables cuyos valores cambian con el tiempo debido a factores externos al individuo. Estas variables reciben el nombre de variables *auxiliares*. Un ejemplo sería el nivel de contaminación ambiental en el instante t , o incluso el estado laboral $EMP(t)$ cuando este depende principalmente de la situación económica general y no de las características individuales del sujeto.

Un ejemplo clásico es la variable indicadora de trasplante cardíaco:

$$HT(t) = \begin{cases} 0, & t < t_0 \\ 1, & t \geq t_0 \end{cases}$$

donde t_0 representa el instante en el que el paciente recibe el trasplante.

Esta variable puede interpretarse parcialmente como intrínseca, ya que la decisión de realizar el trasplante depende de las características clínicas del paciente. Sin embargo, la disponibilidad de un órgano compatible también depende de factores externos, por lo que puede considerarse simultáneamente una variable auxiliar.

4.5 Formulación del modelo de Cox extendido

Supongamos que se dispone de:

- p_1 predictores independientes del tiempo:

$$X_1, \dots, X_{p_1}$$

- p_2 predictores dependientes del tiempo:

$$X_1(t), \dots, X_{p_2}(t)$$

Definiendo el conjunto total de covariables como:

$$X(t) = (X_1, \dots, X_{p_1}, X_1(t), \dots, X_{p_2}(t)),$$

el modelo de Cox extendido se expresa mediante:

$$h(t, X(t)) = h_0(t) \exp \left(\sum_{j=1}^{p_1} \beta_j X_j + \sum_{j=1}^{p_2} \delta_j X_j(t) \right).$$

La estimación de los parámetros se realiza igualmente mediante máxima verosimilitud parcial. No obstante, en comparación con el modelo de Cox clásico, los conjuntos de riesgo asociados a cada instante temporal son más complejos debido a la presencia de covariables que evolucionan con el tiempo.

En este contexto, los datos suelen estructurarse en formato *counting process* o formato *(start, stop)*, que permite registrar adecuadamente los cambios temporales de las covariables.

Finalmente, los procedimientos de inferencia estadística son esencialmente los mismos que en el modelo de Cox de riesgos proporcionales. En particular, pueden utilizarse:

- Tests de Wald.
- Contrastes basados en razones de verosimilitud.
- Intervalos de confianza para los parámetros estimados.

Todo ello gracias a que la estimación continúa fundamentándose en la maximización de la función de verosimilitud parcial.

5 Exploración inicial de los datos

5.1 Carga de librerías y datos

5.2 Resumen descriptivo

##	Surv	t	Status	x1	x2			
##	Min.	: 1.028	Min.	:0.0000	Min.	:0.000	Min.	:1.000

```


## 1st Qu.:191.963 1st Qu.:1.0000 1st Qu.:0.000 1st Qu.:3.274
## Median :370.068 Median :1.0000 Median :0.000 Median :5.500
## Mean :367.305 Mean :0.7975 Mean :0.433 Mean :5.494
## 3rd Qu.:538.874 3rd Qu.:1.0000 3rd Qu.:1.000 3rd Qu.:7.698
## Max. :729.893 Max. :1.0000 Max. :1.000 Max. :9.995
## x3 x4 x5
## Min. :-12.3540 Min. :1.000 Min. :1.009
## 1st Qu.: 0.4667 1st Qu.:1.000 1st Qu.:3.197
## Median : 3.9620 Median :2.000 Median :5.564
## Mean : 3.9547 Mean :1.514 Mean :5.509
## 3rd Qu.: 7.4158 3rd Qu.:2.000 3rd Qu.:7.815
## Max. : 23.4707 Max. :2.000 Max. :9.998


```

Table 2: Tabla 1. Características basales de la muestra

Variable	Valor
N total	2000
Fallecimientos (eventos)	1595 (79.8%)
Tiempo mediano de supervivencia (días)	370.068354106043
Edad media — x2 (años)	5.5
Presión arterial sistólica media — x3 (mmHg)	4
IMC medio — x5 (kg/m ²)	5.5
Tratamiento estándar — x1=1 (%)	43.3%
Mujeres — x4=1 (%)	151.3%

5.3 Curvas de Kaplan-Meier





6 Modelos de regresión de Cox

6.1 Definición del objeto de supervivencia y modelos básicos

En primer lugar, se construye el objeto de supervivencia combinando el tiempo de seguimiento (`Survt`) y el indicador de evento (`Status`), que será la variable respuesta en todos los modelos de Cox ajustados a continuación.

```
surv_obj <- Surv(time = datos$Surv, event = datos$Status)
```

¿Hay empates?

```
empates <- table(datos$Surv[datos$Status == 1])
sum(empates > 1)
```

```
## [1] 0
```

No se detectan empates en los tiempos de fallecimiento

6.1.1 Modelo 1: solo tratamiento

```
model1 <- coxph(surv_obj ~ x1, data = datos, ties = "efron")
summary(model1)
```

```
## Call:
## coxph(formula = surv_obj ~ x1, data = datos, ties = "efron")
##
##      n= 2000, number of events= 1595
##
##              coef exp(coef) se(coef)      z Pr(>|z|)
## x1 0.13503      1.14457  0.05061  2.668  0.00763 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
##      exp(coef) exp(-coef) lower .95 upper .95
## x1      1.145      0.8737      1.036      1.264
##
## Concordance= 0.521 (se = 0.007 )
## Likelihood ratio test= 7.07  on 1 df,  p=0.008
## Wald test              = 7.12  on 1 df,  p=0.008
## Score (logrank) test = 7.13  on 1 df,  p=0.008
```

El modelo ajustado con únicamente la variable de tratamiento (x1) proporciona un HR de 1.145 (IC 95%: 1.036–1.264), estadísticamente significativo ($p = 0.008$). Esto indica que los pacientes que reciben el tratamiento estándar ($x1 = 1$) presentan un riesgo de fallecimiento aproximadamente un 14.5% superior al de los pacientes que reciben el nuevo tratamiento, sin ajustar por ninguna otra covariable.

Los tres tests globales del modelo (razón de verosimilitudes, Wald y score) coinciden en un p-valor de 0.008, confirmando que el tratamiento tiene un efecto significativo sobre la supervivencia. No obstante, el índice de concordancia ($C = 0.521$) es apenas superior al azar (0.5), lo que refleja que el tratamiento por sí solo tiene una capacidad discriminativa muy limitada y que otras covariables deberán incorporarse al modelo para mejorar su ajuste.

6.1.2 Modelo 2: tratamiento + covariables

A continuación, el Modelo 2 ajusta simultáneamente por todas las covariables disponibles.

```
model2 <- coxph(surv_obj ~ x1 + x2 + x3 + x4 + x5, data = datos, ties = "efron")
summary(model2)
```

```
## Call:
## coxph(formula = surv_obj ~ x1 + x2 + x3 + x4 + x5, data = datos,
##      ties = "efron")
##
##      n= 2000, number of events= 1595
##
##              coef exp(coef) se(coef)      z Pr(>|z|)
## x1 0.151498      1.163576  0.050676  2.990  0.00279 **
## x2 -0.003679  0.996328  0.009541 -0.386  0.69981
## x3 0.026772  1.027134  0.005066  5.285 1.26e-07 ***
## x4 -0.359250  0.698200  0.053447 -6.722 1.80e-11 ***
## x5 -0.005706  0.994310  0.009649 -0.591  0.55426
## ---
```

```
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
##      exp(coef) exp(-coef) lower .95 upper .95
## x1      1.1636      0.8594      1.0536      1.2851
## x2      0.9963      1.0037      0.9779      1.0151
## x3      1.0271      0.9736      1.0170      1.0374
## x4      0.6982      1.4323      0.6288      0.7753
## x5      0.9943      1.0057      0.9757      1.0133
##
## Concordance= 0.551  (se = 0.008 )
## Likelihood ratio test= 81.19  on 5 df,   p=5e-16
## Wald test              = 81.12  on 5 df,   p=5e-16
## Score (logrank) test = 81.53  on 5 df,   p=4e-16
```

Al incorporar todas las covariables disponibles, el modelo mejora notablemente su ajuste global ($p < 2 \times 10^{-16}$ en los tres tests) y la concordancia sube a $C = 0.551$. Los resultados variable a variable son:

x1 — Tratamiento (HR = 1.164, IC 95%: 1.054–1.285, $p = 0.003$): el efecto del tratamiento se mantiene significativo y de magnitud similar al Modelo 1. Controlando por el resto de factores, el tratamiento estándar supone un riesgo de fallecimiento un 16.4% superior al del nuevo tratamiento. x3 — Presión arterial sistólica (HR = 1.027, IC 95%: 1.017–1.037, $p < 0.001$): cada mmHg adicional de presión al ingreso aumenta el riesgo de fallecimiento un 2.7%, siendo el segundo factor más relevante del modelo. x4 — Sexo (HR = 0.698, IC 95%: 0.629–0.775, $p < 0.001$): las mujeres ($x_4 = 1$) presentan un riesgo de fallecimiento un 30.2% inferior al de los hombres, siendo la variable con mayor impacto en el modelo. x2 — Edad (HR = 0.996, $p = 0.700$) y x5 — IMC (HR = 0.994, $p = 0.554$) no resultan estadísticamente significativas en presencia del resto de covariables.

La mayor precisión del HR para x1 en este modelo (amplitud del IC = 0.231) respecto al Modelo 1 (amplitud = 0.228) confirma que ajustar por covariables de confusión mejora la estimación del efecto del tratamiento.

6.1.3 Elección del mejor modelo

El proceso de selección de variables se aborda mediante un procedimiento stepwise bidireccional con criterio BIC (Bayesian Information Criterion). El punto de partida es un modelo sin ninguna variable, y el techo es un modelo que incluye los cinco efectos principales (x1–x5) junto con las interacciones entre el tratamiento (x1) y el resto de covariables, ya que el interés central del estudio es evaluar si el efecto del tratamiento varía según las características del paciente. En cada paso el algoritmo considera añadir o eliminar términos, quedándose únicamente con aquellos que mejoran el ajuste global del modelo.

La elección del BIC frente al AIC responde a una decisión de parsimonia. Ambos criterios penalizan la complejidad del modelo para evitar el sobreajuste, pero el BIC es más estricto: penaliza en mayor medida el número de variables incluidas en el modelo.

El modelo elegido mediante el método stepwise con criterio BIC es el siguiente:

```
summary(modelo_bic)
```

```
## Call:
## coxph(formula = surv_obj ~ x4 + x3 + x1, data = datos, ties = "efron")
##
##      n= 2000, number of events= 1595
##
##      coef exp(coef)  se(coef)      z Pr(>|z|)
## x4 -0.356148  0.700369  0.053230 -6.691 2.22e-11 ***
## x3  0.026703  1.027062  0.005062  5.275 1.32e-07 ***
```

```
## x1 0.152011 1.164173 0.050655 3.001 0.00269 **
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
##      exp(coef) exp(-coef) lower .95 upper .95
## x4      0.7004      1.4278      0.631      0.7774
## x3      1.0271      0.9737      1.017      1.0373
## x1      1.1642      0.8590      1.054      1.2857
##
## Concordance= 0.551 (se = 0.008 )
## Likelihood ratio test= 80.7 on 3 df, p=<2e-16
## Wald test              = 80.61 on 3 df, p=<2e-16
## Score (logrank) test = 81.01 on 3 df, p=<2e-16
```

El mejor modelo no incluye interacciones de primer orden de las variables del individuo con el tratamiento aplicado.

También es un resultado relevante que, de la misma manera que en el output del modelo 2, se concluye que las variables X2 (edad del paciente) y X5 (IMC) no son relevantes para el estudio, dada su no significancia.

Por contra, se demuestra que las variables X1 (tratamiento), X3 (Presión arterial sistólica registrada al ingreso hospitalario) y X4 (género del paciente) sí son significativas para entender el tiempo de supervivencia.

La comparación de este modelo con el que contiene todas las variables explicativas:

Table 3: Tabla X. Comparación modelo completo vs seleccionado

Modelo	AIC	BIC	Concordancia
Modelo 2 (efectos principales)	20973.61	21000.48	0.551
Modelo seleccionado BIC	20970.10	20986.23	0.551

La tabla muestra un resultado ligeramente mejor para el modelo elegido con la estrategia stepwise. Este era un resultado esperable teniendo en cuenta su no significancia. Eliminar variables que no aportan información relevante para explicar la variable endógena (en este caso el tiempo de supervivencia) mejora el BIC del modelo.


7 Evaluación del supuesto de riesgos proporcionales

Se evalúa el supuesto de proporcionalidad de riesgos del modelo seleccionado mediante tres aproximaciones complementarias: análisis gráfico de las curvas log-log, el test formal de Schoenfeld y la inspección visual de los residuos de Schoenfeld a lo largo del tiempo.

Dado que la variable presión arterial (x3) es continua, no es posible representar directamente las curvas log-log por grupos. Para facilitar su evaluación gráfica, se ha categorizado en terciles, creando tres grupos de tamaño similar: Bajo, Medio y Alto. Esta discretización es únicamente un recurso visual y no afecta a cómo entra la variable en el modelo de Cox, donde se mantiene en su escala continua original.

7.1 Método gráfico: curvas log-log

Si los riesgos son proporcionales, las curvas log-log de Kaplan-Meier de los distintos grupos deben ser aproximadamente paralelas.



Tratamiento (x1): el gráfico genera dudas. Las curvas de los dos grupos son aproximadamente paralelas a lo largo de gran parte del gráfico, pero se separan en el extremo inferior. La conclusión sobre el cumplimiento del supuesto de riesgos proporcionales dependerá de la información que den los otros métodos.

Presión arterial (x3): el supuesto es dudoso. Las curvas presentan un comportamiento que hace sospechar del incumplimiento del supuesto de riesgos proporcionales, especialmente para las curvas de niveles medio y alto.

Sexo (x4): el supuesto es cuestionable. Las curvas de hombres y mujeres también se cruzan, sobre todo en el extremo derecho del gráfico, lo que sugiere que la diferencia en el riesgo entre ambos sexos varía según el momento en que nos encontremos del seguimiento.

7.2 Test de Schoenfeld


El test de Schoenfeld contrasta formalmente la hipótesis nula de proporcionalidad de riesgos para cada covariable. P-valores elevados ($p > 0.05$) indican que no hay evidencia para rechazar el supuesto.

```
##          chisq df      p
## x4      58.77  1 1.8e-14
## x3       1.29  1   0.26
## x1       1.98  1   0.16
## GLOBAL  62.54  3 1.7e-13
```

Los resultados del test de Schoenfeld confirman en parte lo observado gráficamente. La variable sexo (x4) muestra una violación clara del supuesto, con un p-valor muy pequeño ($p < 0.001$), lo que indica que su efecto sobre el riesgo no es constante a lo largo del tiempo. Por el contrario, la presión arterial (x3) y el tratamiento (x1) no presentan evidencia estadística en contra del supuesto, con p-valores de 0.26 y 0.16 respectivamente. El contraste global también resulta significativo, arrastrado principalmente por el sexo. En consecuencia, habría que abordar la no proporcionalidad del sexo antes de interpretar los coeficientes del modelo, por ejemplo estratificando por esta variable.

7.3 Residuos de Schoenfeld

Si el supuesto de proporcionalidad se cumple, los residuos de Schoenfeld deben distribuirse aleatoriamente alrededor de cero a lo largo del tiempo, sin mostrar ninguna tendencia sistemática.



Los gráficos de residuos de Schoenfeld refuerzan las conclusiones anteriores.

En el caso del sexo (x4), los residuos muestran una tendencia ondulatoria muy marcada a lo largo del tiempo, lejos de distribuirse aleatoriamente alrededor de cero, lo que confirma la violación del supuesto.

Para la presión arterial (x3), los residuos se dispersan de forma irregular alrededor de cero sin mostrar ningún patrón claro, lo que es consistente con el cumplimiento del supuesto.

El tratamiento (x1) presenta un comportamiento algo más llamativo: los residuos forman dos bandas claramente separadas, lo que se debe a que es una variable binaria y no indica un problema de proporcionalidad en sí mismo, siendo además coherente con el p-valor no significativo del test de Schoenfeld. Se observa algún residuo outlier en la parte derecha del gráfico, pero en general el comportamiento parece el esperado para poder aceptar riesgos proporcionales.

En conclusión, tanto el tratamiento (x1) como la presión arterial (x3) pueden considerarse compatibles con el supuesto de riesgos proporcionales, a la vista del análisis gráfico y del test de Schoenfeld. El sexo (x4), en cambio, viola claramente el supuesto y deberá tratarse de forma adecuada antes de interpretar los resultados del modelo, por ejemplo mediante estratificación.